# ÉCOLE NATIONALE DES CHARTES

Jade Norindr

licenciée ès lettres

# Le traitement des sources historiques par la vision artificielle

L'exemple des manuscrits d'astronomie de tradition ptoléméenne

Mémoire pour le diplôme de master « Technologies numériques appliquées à l'histoire »

# Résumé

## Résumé

**Mots-clés**: histoire des sciences; diagrammes astronomiques; images; *machine learning*; vision artificielle; apprentissage profond; YOLOv5; réseau de neurones artificiels; automatisation; Python; programmation modulaire; IIIF; API; Flask.

Informations bibliographiques : Jade Norindr, Le traitement des sources historiques par la vision artificielle. L'exemple des manuscrits d'astronomie de tradition ptoléméenne, mémoire de master « Technologies numériques appliquées à l'histoire », dir. Maxime Challon, École nationale des chartes, 2023.

# Remerciements

# Bibliographie

- BAUJARD (Corinne), « Numérisation du patrimoine culturel et stratégie managériale des musées », Management des technologies organisationnelles—7 (févr. 2017), p. 69-78, URL: https://www.cairn.info/revue-management-des-technologies-organisationnelles-2017-2-page-69.htm (visité le 06/08/2023).
- BENHAMOU (Yaniv), « Droit d'auteur et musées numériques », Magazine de l'OMPI-3 (juin 2016), URL: https://www.wipo.int/wipo\_magazine/fr/2016/03/article\_0005.html (visité le 06/08/2023).
- BERGSTROM (Austin C.) et MESSINGER (David W.), « Image Quality and Computer Vision Performance : Assessing the Effects of Image Distortions and Modeling Performance Relationships Using the General Image Quality Equation », *Journal of Electronic Imaging*, 32 (mars 2023), p. 023018, DOI: 10.1117/1.JEI.32.2.023018.
- Besse (Camille), Numérisation de Masse : Vers La Création d'un Nouvel Acteur de l'information. Le Projet Time Machine, Paris, 2019.
- CLAERR (Thierry) et WESTEEL (Isabelle), « Mode d'emploi », dans *Numériser et mettre en ligne*, Villeurbanne, 2017 (La Boîte à outils), p. 7-18, DOI : 10.4000/books.pressesenssib.419.
- CRAMER (Tom), The International Image Interoperability Framework (IIIF): Laying the Foundation for Common Services, Integrated Resources and a Marketplace of Tools for Scholars Worldwide, déc. 2011, URL: https://www.cni.org/topics/information-access-retrieval/international-image-interoperability-framework (visité le 08/08/2023).
- DENOYELLE (Martine), A propos du coût des images d'œuvres patrimoniales, Billet, juin 2021, URL: https://numrha.hypotheses.org/2142 (visité le 06/08/2023).
- En savoir plus sur la licence Etalab et les autres licences, Billet, juin 2021, URL : https://numrha.hypotheses.org/2134 (visité le 06/08/2023).
- $Digital\ Images,\ 2020,\ URL: https://livecode.byu.edu/images/DigitalImages.php$  (visité le 07/08/2023).
- EVANS (James), « History of Astronomy », dans *Encyclopedia Britannica*, URL: https://www.britannica.com/science/astronomy/Ancient-Greece (visité le 03/08/2023).

viii BIBLIOGRAPHIE

Jeffrey F. Hamburger, David J. Roxburgh et Linda Safran (éd.), *The Diagram as Paradigm : Cross-Cultural Approaches*, Cambridge, MA, 2022 (Dumbarton Oaks Byzantine Symposia and Colloquia).

- How It Works, URL: https://iiif.io/get-started/how-iiif-works/ (visité le 08/08/2023).
- IIIF for Museums in France, juill. 2023, URL: https://www.culture.gouv.fr/en/ Thematic/Museums/Pour-les-professionnels/Network/IIIF-for-museumsin-France (visité le 09/08/2023).
- IIIF Viewers, URL : https://iiif.io/get-started/iiif-viewers/ (visité le 08/08/2023).
- $\it Iiif-Downloader, URL: https://github.com/Segolene-Albouy/iiif-downloader/tree/main (visité le <math>09/08/2023$ ).
- Image API 3.0, URL: https://iiif.io/api/image/3.0/ (visité le 08/08/2023).
- INSTITUT NATIONAL D'HISTOIRE DE L'ART, Guide Pratique Pour La Recherche et La Réutilisation Des Images d'œuvres d'art, URL: https://www.inha.fr/\_resources/PDF/2021/2021\_LIVRET\_GUIDE-PRATIQUE\_web\_15062021.pdf.
- JACQUOT (Olivier), Décrire, transcrire et diffuser un corpus documentaire hétérogène : méthodes, formats, outils, Billet, nov. 2017, URL: https://bnf.hypotheses.org/2214 (visité le 06/08/2023).
- Jardine (Boris) et Jardine (Nicholas), « Critical Editing of Early-Modern Astronomical Diagrams », Journal for the History of Astronomy, 41–3 (août 2010), p. 393-414, doi: 10.1177/002182861004100307.
- JONES (Alexander Raymond), « Ptolemy », dans *Encyclopedia Britannica*, URL : https://www.britannica.com/biography/Ptolemy (visité le 03/08/2023).
- MALLORY (Gavin), IIIF for Museums, Explained, juill. 2019, URL: https://blog.cogapp.com/iiif-for-museums-explained-49fd0560e1ba (visité le 09/08/2023).
- MANCA (Isabelle), « Les nouveaux défis des agences photographiques des musées », Le  $Journal\ Des\ Arts$  (, juin 2018), URL : https://www.lejournaldesarts.fr/patrimoine/les-nouveaux-defis-des-agences-photographiques-des-musees-138076 (visité le 06/08/2023).
- MONNIER (Tom), VINCENT (Elliot), PONCE (Jean) et Aubry (Mathieu), Unsupervised Layered Image Decomposition into Object Prototypes, août 2021, DOI: 10.48550/arXiv.2104.14575, arXiv: 2104.14575 [cs].
- Presentation API 3.0, URL : https://iiif.io/api/presentation/3.0/ (visité le 08/08/2023).
- RICHARD (Michel), « Le programme de numérisation de la Bibliothèque de France », Bulletin des bibliothèques de France-3 (1993), p. 53-63, URL: https://bbf.enssib.fr/consulter/bbf-1993-03-0053-007 (visité le 06/08/2023).

BIBLIOGRAPHIE ix

ROUSSEAU (Jean-Jacques), *Epicycles de Ptolémée*, URL : http://ressources.univ-lemans.fr/AccesLibre/UM/Pedago/physique/02/divers/ptolemee.html (visité le 05/08/2023).

- SAKAI (Akira), Digitizing Disparity in the Museum. The Object-Based Research in the Tokyo National Museum, août 2021, URL: https://universityheritage.eu/en/digitizing-disparity-in-the-museum-the-object-based-research-in-the-tokyo-national-museum/ (visité le 06/08/2023).
- SEPETJAN (Sophie), « Respecter le droit de la propriété littéraire et artistique », dans Numériser et mettre en ligne, dir. Thierry Claerr et Isabelle Westeel, Villeurbanne, 2017 (La Boîte à outils), p. 46-64, DOI: 10.4000/books.pressesenssib.426.

 ${f x}$  BIBLIOGRAPHIE

# Introduction

xii BIBLIOGRAPHIE

# Première partie

# Construire un corpus de numérisations pour le traitement par vision artificielle

# Chapitre 1

# Le projet EiDA

# 1.1 Contexte et objectifs du projet

# 1.1.1 Un projet de recherche en humanités numériques

## Cadre du projet

Les sciences astronomiques se développent, à travers les siècles, à l'intersection de besoins et de questionnements divers auxquels elles tentent de répondre. Des besoins politiques aux besoins religieux, ces disciplines existent au cœur de contextes culturels, géographiques, historiques variés et interconnectés, et produisent, dans le cadre de leur pratique, des supports éclectiques qui témoignent de l'évolution des idées, et des conceptions du monde et de l'univers. Les manuscrits et imprimés produits dans le cadre des sciences astronomiques, pour répondre aux besoins de ceux qui les emploient, comportent des tables, des textes et des diagrammes d'une grande richesse, à l'image de la diversité de leurs contextes de production et de leurs utilisations.

Le projet EIDA (Editing and analysing hIstorical astronomical Diagrams with Artificial intelligence) 1, ayant pour vocation d'analyser ces sources dans le cadre de l'histoire des sciences, s'intéresse plus spécifiquement aux diagrammes astronomiques, en tant que patrimoine visuel et supports pour la circulation des idées et théories astronomiques et mathématiques. L'étude de ces circulations implique l'exploitation d'un corpus large, représentatif des bornes chronologiques et géographiques du projet, qui s'étendent de l'Europe à l'Asie du VIII<sup>e</sup> au XVIII<sup>e</sup> siècle. Le projet EIDA a pour objectif d'étudier la diversité des diagrammes produits, du point de vue de l'utilisation mais aussi du support et de la diffusion. Les diagrammes sont étudiés d'une point de vue épistémique, par la définition de différentes typologies de diagrammes, l'analyse de leurs utilisations dans divers contextes et l'étude des sujets mathématiques et astronomiques qui les implique; ainsi que d'un point de vue documentaire, avec un intérêt pour leurs contextes de production,

<sup>1.</sup> ANR-22-CE38-0014

le rapport texte-diagramme dans les manuscrits, et la circulation des représentation à une échelle locale ou globale.

Le projet s'appuie sur des sources latines, byzantines, arabes, persanes, hébraïques, sanskrites et chinoises, qui partagent des éléments communs permettant ainsi de retracer les évolutions des sciences astronomiques, et d'étudier leur continuité, leur diversité, et leurs connections à travers l'histoire de l'astronomie.

#### Le choix de la vision artificielle

Profondément ancré dans les méthodes des humanités numériques, le projet EIDA a pour objectif le développement d'une approche reposant sur la vision artificielle, qui permettrait d'appliquer au corpus une série de traitements en prévision de leur analyse et de leur exploitation. Le développement d'outils basés sur la vision artificielle a pour but de limiter les étapes manuelles de fouille et d'annotation dans le corpus de manuscrits, en automatisant les étapes d'extraction des diagrammes dans les numérisations, et leur transformation en objets aisément manipulables pour leur analyse, comme pour l'édition. La projet EIDA repose ainsi, dans ses principes fondateurs, sur une approche interdisciplinaire mêlant histoire des sciences et vision artificielle, avec pour objectif l'analyse de sources historiques dans le domaine des sciences astronomiques et le développement d'outils pour l'étude des diagrammes.

Dans une perspective de science ouverte, le projet EIDA prévoit le développement d'une application Web dédiée à l'extraction, la visualisation, l'étude et l'édition de diagrammes; une plateforme dédiée à la communauté de la recherche qui permettra une utilisation des données produites et des outils développés par EIDA via une interface web. Cette plateforme permettra à un public de chercheurs, d'étudiants ou d'amateurs d'exploiter les algorithmes développés dans le cadre du programme pour traiter leurs propres sources; à l'image de la plateforme développée dans le cadre du projet DISHAS (Digital Information System for the History of Astral Sciences), dédié aux tables astronomiques.

#### Annotations et données ouvertes

Le projet EIDA ayant pour objectif de produire un modèle de vision par ordinateur performant pour la détection de diagrammes dans des numérisations de manuscrits, un jeu de données d'entraînement – ou vérité de terrain – est produit à partir d'annotations réalisées par les chercheurs du programme. Ce jeu de données est composé d'un ensemble d'images et de leurs fichiers d'annotation où sont localisés manuellement les diagrammes, selon les résultats espérés de la détection automatique. Cette vérité de terrain se veut, pour des meilleurs résultats, la plus exhaustive possible quant au matériau source, et constitue ainsi un jeu de données diversifié en termes d'images et d'annotations, aussi bien du point de vue de la période que de la provenance géographique, ou simplement du

style de représentation.

EIDA prévoit ainsi de mettre à disposition ce jeu de données, pour permettre son exploitation par d'autres projets qui souhaiteraient entraîner un modèle de vision artificielle pour la détection d'objets dans des images. Il est envisagé, pour le bon référencement de ce jeu de données, de les référencer dans un catalogue à l'image de l'initiative HTR-United <sup>2</sup> pour la reconnaissance automatique des écritures manuscrites. L'annotation étant une étape cruciale des projets en *machine learning*, l'ouverture de ces données permettra ainsi à d'autres projets de bénéficier du travail effectué dans le cadre d'EIDA.

# 1.1.2 Avant EiDA: le projet DISHAS

## Étudier les tables astronomiques

Précédant le projet EIDA, DISHAS s'intéresse au développement des sciences astronomiques, à leur circulation, à leur transmission à travers les cultures et les époques, par le prisme des tables. De la même manière que les diagrammes sont un objet d'étude permettant de retracer des traditions scientifiques à travers les cultures eurasiennes, les tables sont un objet caractéristique des sciences astronomiques, dont le contenu numérique rend possible l'alignement et la comparaison entre différentes sources pour une étude de la circulation des idées entre les cultures et les pratiques scientifiques.

Le projet DISHAS emploie les méthodologies des humanités numériques et les applique au traitement des sources en histoire de l'astronomie. Dans cette optique, une application dédiée à l'édition et à l'analyse des tables astronomiques a été mise en ligne <sup>3</sup> : cette application propose une contextualisation historique, chronologique et géographique des tables <sup>4</sup>, ainsi qu'une série d'outils plus spécifiques, pour leur étude par un public divers, plus ou moins spécialisé. Parmi ces outils dédiés au traitement des tables, DTI (DISHAS Table Interface) est destiné à la saisie de tables numériques et DIPS (DISHAS Interactive Parameter Squeezer) propose l'analyse mathématique de tables astronomiques anciennes; mettant ainsi à disposition de la communauté de la recherche les résultats du projet, pour que les données comme les outils puissent être utilisés dans le cadre de recherches dans le domaine de l'histoire des sciences.

#### Approche par la vision artificielle

L'approche des données visuelles par l'intelligence artificielle est un élément clé du projet DISHAS, ayant donné lieu au développement de tableTranscriber <sup>5</sup>, un outil dédié

<sup>2.</sup> HTR-United ne propose pas de cataloguer des jeux de données pour la *computer vision*, il est cependant envisagé de prendre contact avec les porteurs de l'initiative pour discuter de la possible intégration des données du projet EIDA.

<sup>3.</sup> DISHAS project

<sup>4.</sup> Historical navigation — DISHAS project

<sup>5.</sup> tableTranscriber

à la détection par un algorithme de vision artificielle <sup>6</sup> de la structure des tables, afin d'en transcrire le contenu manuscrit à l'aide d'un algorithme de HTR. L'objectif de table-Transcriber est ainsi d'automatiser la chaîne de traitement des numérisations de tables astronomiques manuscrites, afin d'obtenir des données au format XML, CSV ou HTML, aisément manipulables pour une analyse des sources.

Cette volonté collaborative dans le développement d'outils numériques est centrale au projet EIDA qui, comme son prédécesseur DISHAS, vise à produire une recherche communautaire, aux acteurs scientifiques divers, à l'intersection des humanités numériques et de l'histoire des sciences.

# 1.1.3 Acteurs du projet

#### SYRTE-PSL-Observatoire de Paris, CNRS

EIDA est un projet interdisciplinaire mené en collaboration avec de nombreux acteurs et institutions, pour en faire un projet réellement collaboratif dans la réalisation de ses objectifs. Au sein de l'Observatoire de Paris, l'équipe est composée d'historiens et d'ingénieurs affiliés au SYRTE (Systèmes de Référence Temps-Espace), ayant pour la plupart collaboré au projet DISHAS, et possédant donc une expérience de la recherche en histoire des sciences, et en humanités numériques. L'équipe compte également des chercheurs indépendants et collaborateurs scientifiques externes, qui assurent la diversité du corpus en contribuant à EIDA par leur expertise dans des sources issues d'aires géographiques et chronologiques qui s'ajoutent à celles représentées dans l'équipe d'histoire des sciences de l'Observatoire de Paris.

Du point de vue des institutions, le groupe de recherche en vision artificielle IMAGINE (Laboratoire d'Informatique Gaspard Monge) basé à l'École des Ponts ParisTech, co-coordonne le projet EIDA, et assure notamment les recherches en vision artificielle et apprentissage machine nécessaires à la réalisation des objectifs du projet. Le projet VHS (Vision artificielle et analyse Historique de la circulation de l'illustration Scientifique), coordonné par l'Institut des sciences du calcul et des données, est également partenaire d'EIDA pour le développement des algorithmes de détection et de la plateforme dédiée aux chercheurs.

### Algorithmes de vision par ordinateur : le groupe de recherche IMAGINE

L'équipe IMAGINE – avec laquelle l'équipe d'histoire des sciences avait déjà collaboré pour le développement de tableTranscriber dans le projet DISHAS— apporte au projet EIDA son expertise dans le domaine de l'apprentissage profond et de la vision artificielle appliqués aux humanités numériques. Les recherches menées entre 2018 et 2022 dans le

<sup>6.</sup> Basé sur docExtractor.

cadre du projet EnHerit<sup>7</sup>, dédié à l'application d'algorithmes de vision à l'histoire de l'art pour la reconnaissance de motifs dans les œuvres d'art, sont le socle des développements menés pour les projets EIDA et VHS.

Dans le cadre de leur participation à EIDA, l'objectif des chercheurs d'IMAGINE est le développement de nouvelles approches <sup>8</sup> pour permettre la décomposition et la vectorisation de dessins techniques. Ces nouvelles approches par vision par ordinateur devraient permettre l'analyse et l'édition de diagrammes astronomiques sans intervention humaine, avec une méthode plus flexible dans son apprentissage, qui allègerait ainsi les étapes d'annotation nécessaires à l'apprentissage profond.

Ces recherches en apprentissage faiblement supervisé sont également menées dans le cadre du projet VHS, auquel l'équipe IMAGINE contribue également, avec un accent mis sur la détection de similarité dans les images et dans le texte, qui devraient permettre une navigation facilitée des corpus étudiés, et qui seront également exploitées dans EIDA.

## Le projet ANR VHS

Le projet VHS réunit des chercheurs en histoire des sciences et en vision artificielle pour l'étude de la circulation des savoirs scientifiques au Moyen-Âge et à la période moderne. Coordonné par Alexandre Guilbaud, VHS a pour objectif de développer des méthodes d'analyse de corpus illustrés par apprentissage profond, afin d'étudier la circulation, l'évolution et la réutilisation des images scientifiques dans le cadre de la transmission des savoirs à travers les époques et les zones géographiques, et d'analyser le rapport des images au contenu textuel des ouvrages dans lesquels elles figurent. Les méthodes développées par le projet ont pour objectif de limiter la nécessité des annotations pour l'obtention de résultats dans la détection de similarité, qui permettraient ainsi de faciliter la navigation de corpus scientifiques par des regroupements et rapprochements basés sur les images et sur le texte.

Ces recherches s'accompagnent du développement d'une application Web, qui mettra à disposition de la communauté scientifique les outils et données produites dans le cadre du projet VHS, afin que ceux-ci puissent être exploités par d'autres équipes travaillant dans le domaine des études visuelles, ou souhaitant apporter une analyse sur des corpus illustrés par le prisme de la circulation des motifs et des idées.

Les membres des équipes IMAGINE sont sollicités lors des prises de décision relatives aux recherches menées par les chercheurs <sup>9</sup> et participent aux discussions relatives au développement de la plateforme. De plus, pour un développement plus fluide des applications VHS et EIDA, l'ingénieur chargé de ce développement pour le projet VHS mène régulière-

<sup>7.</sup> Enhancing Heritage Image Databases – EnHerit

<sup>8.</sup> Basées sur les progrès récents de l'analyse par synthèse. Tom Monnier, Elliot Vincent, Jean Ponce et Mathieu Aubry, *Unsupervised Layered Image Decomposition into Object Prototypes*, août 2021, DOI: 10.48550/arXiv.2104.14575, arXiv: 2104.14575 [cs]

<sup>9.</sup> On considère l'annotation des diagrammes dans les manuscrits comme un travail de recherche.

ment ses travaux à l'Observatoire, pour faciliter les échanges entre les deux équipes. Ces collaborations permettent ainsi une mutualisation des recherches et expertises des différents projets, ainsi que le développement commun d'outils réutilisables qui bénéficient des regards variés et complémentaires des différents acteurs.

# 1.2 Sources primaires

# 1.2.1 L'astronomie ptoléméenne : naissance et diffusion

# L'Almageste et le modèle ptoléméen

L'astronomie et les disciplines qui y sont liées sont, dès l'Antiquité, cultivées dans un grand nombre de cultures où se développent des pratiques variées, appuyées sur l'observation des objets célestes et le développement de systèmes mathématiques pour en prédire le comportement. Jusqu'à l'arrivée des théories de Nicolas Copernic au  $xv^e$  siècle, les travaux de Ptolémée  $^{10}$  influencent, à travers l'Eurasie, les productions des astronomes. L'œuvre de Ptolémée devient en effet dès le  $II^e$  siècle une référence en matière d'astronomie : développées sur les travaux de ses prédécesseurs grecs, les théories de Ptolémée approfondissent les productions de son temps dont il fait la synthèse dans ses travaux, et qu'il enrichit de ses propres observations. Si le modèle géocentrique est déjà établi avant l'achèvement de L'Almageste, les travaux de Ptolémée perfectionnent la théorie des épicycles  $^{11}$ , et parviennent à l'affiner avec une précision suffisante pour la prédiction des positions des planètes, notamment par l'introduction du point équant  $^{12}$ .

L'Almageste est constitué d'observations et descriptions des procédures mathématiques appliquées par Ptolémée pour établir les paramètres de son modèle géométrique <sup>13</sup>. À ses explications textuelles s'ajoutent des tables de valeurs numériques calculées par

<sup>10.</sup> Claude Ptolémée (v. 100-v. 170) est un astronome, mathématicien et géographe actif à Alexandrie au II<sup>e</sup> siècle de notre ère. *L'Almageste*, complété vers 150, comprend un quart de siècle d'observations des mouvements des objets célestes, expliqués par des systèmes mathématiques qu'il développe dans son œuvre. Le système ptoléméen désigne le modèle géocentrique de l'univers qu'il développe dans ses travaux. Alexander Raymond Jones, « Ptolemy », dans *Encyclopedia Britannica*, URL: https://www.britannica.com/biography/Ptolemy (visité le 03/08/2023).

<sup>11.</sup> Introduite par les astronomes de la Grèce antique, la théorie des épicycles permet, dans un modèle géocentrique, d'expliquer les changements de vitesse et de direction dans le mouvement observé des planètes, du Soleil et de la Lune. Selon cette théorie, les objets célestes se déplacent à vitesse uniforme sur un cercle appelé épicycle, dont le centre est lui-même en rotation sur un cercle centré sur la Terre appelé déférent. Jean-Jacques Rousseau, *Epicycles de Ptolémée*, URL: http://ressources.univ-lemans.fr/AccesLibre/UM/Pedago/physique/02/divers/ptolemee.html (visité le 05/08/2023)

<sup>12.</sup> En effet, la théorie des épicycles telle qu'elle existe avant l'intervention de Ptolémée ne permet pas de justifier précisément des mouvements observés des planètes. Ptolémée introduit ainsi la notion de point équant, point excentré par rapport au centre de la Terre, à partir duquel la vitesse de rotation des corps céleste est constante. Ce modèle géométrique permet de calculer avec précision le mouvement longitudinal des planètes. James Evans, « History of Astronomy », dans *Encyclopedia Britannica*, URL : https://www.britannica.com/science/astronomy/Ancient-Greece (visité le 03/08/2023)

<sup>13.</sup> *Ibid*.

Ptolémée qui permettent, en suivant ses explications, de calculer la position des planètes, en tant qu'application de ses théories. Dans les siècles qui suivent le développement du modèle ptoléméen, peu d'innovations ont lieu dans les sciences astronomiques de tradition hellénique, et les travaux produits prennent essentiellement la forme de commentaires des théories de Ptolémée, sans remise en cause de son modèle, qui reste la norme pendant plusieurs siècles et est diffusé à travers l'Eurasie par le biais de traductions.

#### Diffusion du modèle ptoléméen

Avant les Grecs, les Babyloniens pratiquent, dès le 1<sup>e</sup> millénaire av. J.-C., une astronomie basée sur des calculs arithmétiques permettant de prédire la position des planètes. L'astronomie indienne hérite de ces théories des sciences astronomiques babyloniennes qu'elle mêle avec des méthodes locales, qui s'enrichissent plus tard des travaux de Ptolémée et de son prédécesseur Hipparque, qui voyagent vers l'Est 14 par le biais de la Perse.

À partir du VIII<sup>e</sup> siècle, dans le monde islamique, se développe une pratique de l'astronomie à l'intersection des théories grecques, babyloniennes, perses et indiennes. Suivant le modèle des tables de Ptolémée, les astronomes arabes développent au IX<sup>e</sup> siècle des ouvrages de tables, appelés  $z\bar{\imath}j$ , dédiés au calcul des positions du Soleil, de la Lune et des planètes mêlant ces diverses traditions. La traduction en arabe – pendant le califat abbasside  $^{15}$  – des écrits de Ptolémée permet aux astronomes du monde islamique d'enrichir leurs pratiques en l'inscrivant dans cette tradition, tout en améliorant certains paramètres calculés dans le cadre de son modèle pour en préciser les prédictions  $^{16}$ . Si des critiques des travaux de Ptolémée émergent, notamment au XI<sup>e</sup> siècle dans les écrits d'Ibn al-Haytham, son modèle reste prédominant jusqu'aux travaux de Copernic  $^{17}$ .

Dans le monde latin, les théories grecques se sont peu transmises, et l'enseignement de l'astronomie s'appuie essentiellement sur les écrits de Pline l'Ancien. Au XII $^{\rm e}$  et XIII $^{\rm e}$  siècles, les textes grecs sont rendus disponibles par des initiatives de traduction : Gérard de Crémone, notamment, traduit  $L'Almageste^{18}$  de l'arabe vers le latin, participant activement à la redécouverte du modèle ptoléméen par les scientifiques du monde latin. La transmission des écrits et théories astronomiques ne se fait donc pas directement des Grecs au Latin, mais a pour intermédiaires les traductions effectuées aux siècles prédécents dans le monde arabo-musulman. En parallèle, le développement des universités réintègre

<sup>14.</sup> *Ibid*.

<sup>15.</sup> La dynastie sunite des Abbassides gouverne le monde musulman de 750 à 1258. La capitale du califat, Bagdad, est le siège d'entreprises de traduction vers l'arabe d'écrits scientifiques, notamment depuis le grec.

<sup>16.</sup> L'écart temporel entre les calculs de Ptolémée et ceux des astronomes arabes du IX<sup>e</sup> siècle permettent également de mettre en évidence certains déplacements observables seulement sur un temps plus long, tels que la diminution de l'obliquité de l'écliptique.

<sup>17.</sup> *Ibid*.

<sup>18.</sup> Ainsi que d'autres versions arabes de textes grecs, tels que Du ciel d'Aristote, ou les 'El'ements d'Euclide.

l'astronomie à l'enseignement des arts libéraux : dans ce contexte d'émulation, de nouveaux ouvrages sont publiés, et notamment des tables astronomiques, toujours basés sur le modèle ptoléméen.

Les sources chinoises témoignent d'une pratique de l'astronomie aussi ancienne que le II<sup>e</sup> millénaire av. J.-C. sous la forme de prédiction des éclipses du Soleil et de la Lune. Cette pratique est profondément liée à la culture impériale, et les éclipses – puis plus tardivement, les planètes – sont un outil d'analyse du règne d'un empereur. Plus proche des procédures babyloniennes que du modèle géométrique grec, l'astronomie chinoise s'appuie avant tout sur l'arithmétique pour ses prédictions, et s'intéresse principalement aux événements ponctuels – tels que les comètes ou les éclipses – plutôt qu'aux mouvements des corps célestes <sup>19</sup>.

Jusqu'à l'émergence du modèle héliocentrique, et la mise au centre de la pratique des théories de Copernic, le modèle ptoléméen représente, dans de nombreux contextes culturels, le socle des méthodes des sciences astronomiques. Qu'il soit amélioré, contesté, ou enrichi de pratiques locales, il reste un standard de la conception de l'astronomie en Eurasie, et permet ainsi de retracer une tradition des pratiques à travers les siècles.

# 1.2.2 Les diagrammes

#### Une culture visuelle des sciences astronomiques

Dans le contexte eurasiatique, les supports détaillant les pratiques des astronomes circulent entre les siècles et les cultures, sont enrichis ou adaptés aux pratiques autochtones de l'astronomie, en réponse aux besoins spécifiques de chaque contexte culturel. Les manuscrits et imprimés, supports de ces pratiques, sont les témoins de ces échanges intellectuels et permettent d'établir une histoire des idées et des méthodes héritées du modèle ptoléméen (fig. 1.1). Ces œuvres comprennent, en support des pratiques, des textes, des tables et des diagrammes, tous porteurs des méthodes et théories des sciences astronomiques : le projet DISHAS ayant mené une étude sur les tables astronomiques, il semble naturel qu'EIDA, dans la continuité de celui-ci, ait pour vocation de s'intéresser spécifiquement aux diagrammes. Les astronomes, dans leur pratique, n'hésitent pas à employer des modes d'expression visuels, au-delà du texte, qu'il convient d'étudier en parallèle de celui-ci pour en comprendre les interactions. Ainsi, il est nécessaire de développer des outils permettant d'appréhender les formes variées que peuvent prendre les sources en histoire de l'astronomie; à l'image des récentes recherches en histoire des sciences, qui s'appliquent notamment à une étude des sources visuelles, non-discursives, de la pratique scientifique, et en considérant les illustrations comme des objets d'étude à part entière,

au-delà d'un simple accompagnement du contenu textuel <sup>20</sup>.

En tant que vecteurs d'une culture visuelle de l'astronomie, les diagrammes sont, pour les astronomes, le support d'une pratique scientifique, et sont ainsi révélateurs de leurs méthodes, de leur contexte d'exercice et de leur conception de ces disciplines. Le projet vise à proposer une analyse de ces diagrammes qui souligne la variété de leurs fonctions et des traditions auxquelles ils appartiennent, tout en étudiant leurs modes de circulation à travers l'histoire de l'astronomie. Dans la diversité de leurs sphères de création, ces diagrammes reçoivent « une légitimité en tant qu'instruments pédagogiques et vecteurs de la pensée <sup>21</sup> », et occupent ainsi dans le contexte d'une culture visuelle globale une place particulière.

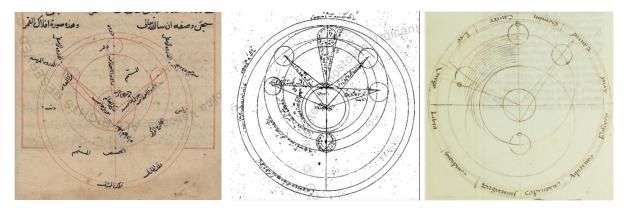


FIGURE 1.1 – Modèles lunaires de tradition arabe, byzantine et latine

#### Bornes géographiques et chronologiques

Ayant la volonté de produire une étude des circulations et évolutions des diagrammes astronomiques, EIDA s'attache à l'étude de sources provenant de sphères géographiques et temporelles larges : les pratiques eurasiatiques des sciences astronomiques partagent des éléments communs qui justifient une étude au cadre vaste, pour proposer une analyse transculturelle des continuités et divergences dans l'histoire de l'astronomie comme dans la culture visuelle. Pour répondre à cette volonté, le projet EIDA s'appuie sur cinq *corpora* aux provenances temporelles et géographiques diverses, provenant de traditions diverses également, dans une volonté de représentativité qui donne sa pertinence à l'étude qui en est faite.

Les manuscrits astronomiques arabo-persans, produits du VIII<sup>e</sup> au XVIII<sup>e</sup> siècle, représentent à eux seuls un corpus d'une grande diversité, aux traditions diverses aussi bien

<sup>20.</sup> Boris Jardine et Nicholas Jardine, « Critical Editing of Early-Modern Astronomical Diagrams », Journal for the History of Astronomy, 41-3 (août 2010), p. 393-414, DOI: 10.1177/002182861004100307, p. 394

<sup>21. « [...]</sup> legitimacy as instruments of pedagogy and as vehicle of thought ». Jeffrey F. Hamburger, David J. Roxburgh et Linda Safran (éd.), *The Diagram as Paradigm : Cross-Cultural Approaches*, Cambridge, MA, 2022 (Dumbarton Oaks Byzantine Symposia and Colloquia), p. 1.

du point de vue des pratiques que de la provenance géographique. Les travaux produits dans ces contextes circulent à travers l'Eurasie du Moyen-Âge au début de la période moderne, et influencent de nombreuses pratiques. Les manuscrits d'astronomie latin médiévaux sont produits majoritairement entre le XIII<sup>e</sup> et le XVI<sup>e</sup> siècle dans un contexte universitaire, et sont influencés par les traductions faites de l'arabe au latin de textes de tradition arabe ou persane. Les manuscrits byzantins, produits entre les IX<sup>e</sup> et XV<sup>e</sup> siècles sont à l'intersection des traditions helléniques, latines et arabo-persanes, et influencent considérablement les manuscrits astronomiques latins du XV<sup>e</sup> et du XVI<sup>e</sup> siècle. Les manuscrits sanskrits, dont la diversité reflète les nombreuses traditions établies sur près de deux millénaires, témoignent à partir du XI<sup>e</sup> siècle d'influences helléniques puis arabo-persanes. Les sources chinoises, dont le support n'est pas nécessairement le manuscrit, prennent souvent la forme d'imprimés par blocs xylographiques dont les matrices sont réemployées à travers plusieurs témoins. Ces documents témoignent des influences arabo-persanes puis latines des pratiques astronomiques chinoises à partir de la dynastie Ming <sup>22</sup>. Les sources étudiées dans le cadre d'EIDA proviennent essentiellement des dynasties Ming et Qing <sup>23</sup>.

Les bornes de ces cinq corpora représentent les bornes chronologiques et géographiques du projet. S'étendant du VIII<sup>e</sup> au XVIII<sup>e</sup> siècle, les périodes et aides étudiées se veulent représentatives du contexte afro-eurasien de la circulation des idées et des images. Ces corpora représentent, dans chaque cas, plusieurs milliers de manuscrits. Plusieurs centaines de manuscrits sont numérisés pour chaque tradition représentée dans le projet, permettant ainsi la représentativité espérée dans le cadre du projet EIDA. Ces numérisations, mises à disposition par les institutions patrimoniales qui conservent ces témoins, représentent les sources primaires du projet, sur lesquelles seront appliquées les traitements en prévision de l'analyse par les chercheurs.

<sup>22.</sup> La dynastie Ming règne sur la Chine de 1368 à 1644.

<sup>23.</sup> La dynastie Qing, dernière dynastie impériale chinoise, règne de 1644 à 1912.

# Chapitre 2

# Images et interopérabilité

# 2.1 L'image comme source

# 2.1.1 Construire un corpus d'images : enjeux et méthodes

#### La numérisation, enjeu patrimonial

L'application à un corpus de sources historiques de méthodes numériques repose sur une première étape cruciale dans le traitement de ces sources : la numérisation des collections patrimoniales. De la bibliothèque au musée, la numérisation du patrimoine culturel est un enjeu crucial depuis le début des années 1990 <sup>1</sup>. Pensée initialement comme un outil de préservation, de valorisation et d'accessibilité aux collections <sup>2</sup>, la mise à disposition des collections au format numérique ouvre également la voie à de nouvelles méthodologies de la recherche, et notamment dans le champs disciplinaire des humanités numériques : dans le cadre d'un projet tel qu'EIDA, qui prévoit des traitements automatiques des sources par des algorithmes de vision par ordinateur, la disponibilité des sources numérisées est un principe fondateur de la démarche de recherche.

La numérisation des données culturelles fait désormais partie des pratiques courantes des institutions culturelles, et plus particulièrement des bibliothèques, représentant une part intégrante du travail de conservation et de diffusion du patrimoine <sup>3</sup>. Dès le milieu 1990, des initiatives telles que Gallica <sup>4</sup>, bibliothèque numérique de la BnF (Bibliothèque nationale de France), voient le jour, et mettent à disposition du publique, au format numé-

<sup>1.</sup> Corinne Baujard, « Numérisation du patrimoine culturel et stratégie managériale des musées », Management des technologies organisationnelles—7 (févr. 2017), p. 69-78, URL: https://www.cairn.info/revue-management-des-technologies-organisationnelles-2017-2-page-69.htm (visité le 06/08/2023).

<sup>2.</sup> Michel Richard, « Le programme de numérisation de la Bibliothèque de France », Bulletin des bibliothèques de France—3 (1993), p. 53-63, URL: https://bbf.enssib.fr/consulter/bbf-1993-03-0053-007 (visité le 06/08/2023).

<sup>3.</sup> Thierry Claerr et Isabelle Westeel, « Mode d'emploi », dans *Numériser et mettre en ligne*, Villeurbanne, 2017 (La Boîte à outils), p. 7-18, DOI: 10.4000/books.pressesenssib.419.

<sup>4.</sup> Gallica

rique, les collections de la bibliothèque. Dans les années qui suivent, des initiatives telles qu'Europeana <sup>5</sup>, portée par Google, permettent le déploiement de projets de plus large envergure <sup>6</sup>, portant toujours cette responsabilité de préservation, diffusion et valorisation des collections dans un contexte international. La notion de patrimoine culturel numérique prend tout son sens, et Internet devient un espace permettant à des utilisateurs aux profils variés d'exploiter ces ressources numériques, et d'accéder à un patrimoine vaste, au-delà des limites physiques de la consultation des documents. Cependant, malgré les initiatives de soutien à la numérisation portées par les collectivités, ou même par l'État <sup>7</sup>, il est nécessaire de souligner les disparités, aussi bien sur le plan national qu'international, de ces entreprises de numérisation, souvent coûteuses : ainsi, il n'existe pas de réelle égalité entre les institutions dans la numérisation et la mise en ligne des collections, un biais qu'il est nécessaire de prendre en compte, et particulièrement dans des projets de recherche appuyés sur des sources aux bornes géographiques internationales.

Dans le cas des *corpora* étudiés par le projet EIDA, on compte, pour des sources qui représentent plusieurs centaines de milliers de documents, une somme de plusieurs centaines de documents numérisés, mis à disposition par les institutions patrimoniales européennes, chinoises et indiennes : nous constatons ainsi que les documents numérisés ne représentent qu'un fragment de la réalité des sources existantes, cependant, ces centaines de documents numérisés sont à la fois suffisantes et suffisamment représentatives pour le bon déroulé du projet.

Les collections patrimoniales des musées présentent un tout autre enjeu en termes de mise en ligne : les œuvres conservées, allant bien au-delà du format livre, ont une diversité qui redéfinit entièrement la notion de numérisation <sup>8</sup>. Tout comme les bibliothèques, les institutions muséales font face, avec le développement des pratiques numériques, à une transformation des pratiques de conservation pour inclure ces méthodes. Outre les aspects documentaires de la numérisation, le Web est un lieu d'exposition à part entière, et la numérisation des œuvres présentent ainsi un intérêt stratégique en termes de valorisation et de visibilité <sup>9</sup>. Dans le monde muséal, néanmoins, l'accès libre aux images n'est pas aussi systématique qu'en bibliothèque <sup>10</sup> : il existe bel et bien des projets de numérisation de grande envergure, tels que Google Arts & Culture <sup>11</sup>, publié en 2011. La vocation de ce type de projets, cependant, semble plutôt être la création d'espaces d'exposition dématérialisés permettant de mettre en valeur les œuvres pour des spectateurs, plutôt que la véritable

<sup>5.</sup> Europeana

<sup>6.</sup> Ibid.

<sup>7.</sup> Ibid.

<sup>8.</sup> Par numérisation, dans le contexte muséal, nous entendons essentiellement la prise de photographies de haute qualité des œuvres d'arts.

<sup>9.</sup> C. Baujard, « Numérisation du patrimoine culturel et stratégie managériale des musées »...

<sup>10.</sup> Pour comparaison, Gallica représente aujourd'hui près de 10 millions de documents, et la base de la Rmn-Grand Palais (Réunion des musées nationaux-Grand Palais) compte 600 000 œuvres numérisées.

<sup>11.</sup> Google Arts & Culture

mise à disposition de ces images pour un usage par des utilisateurs. Nous soulignons, notamment, dans le cas de Google Arts & Culture, l'impossibilité de copier les images avec un clic droit, et l'absence de bouton pour le téléchargement des numérisations sur un certain nombre de pages : les numérisations sont faites pour être vues, et non utilisées <sup>12</sup>.

Une étude menée entre 2019 et 2020 par le Musée National de Tokyo souligne, en parallèle, les disparités dans la qualité des numérisations, qui ne permet ainsi pas de considérer qu'un objet numérisé ou photographié l'est nécessairement dans une qualité exploitable <sup>13</sup>, notamment parce que les besoins en termes de qualité ne sont pas les mêmes pour des œuvres en 2D et des œuvres en 3D, qui souffrent particulièrement de la mauvaise qualité des numérisations. Ainsi, en prenant en compte ces critères, il est nécessaire de soulever la question de la réelle exploitabilité des images mises en ligne, et particulièrement dans le cadre de projets en vision artificielle qui reposent, dans leurs fondations, sur la disponibilité et la qualité des images du corpus choisi. Des initiatives récentes tentent cependant de pallier à ces lacunes des institutions patrimoniales quant à la mise à dispostion des images, comme la création en 2015 d'une API (Application Programming Interface) donnant accès aux reproductions de la base photographie de la Rmn-Grand Palais <sup>14</sup>, mais la norme, pour ces images d'œuvres d'art, reste loin de l'open access <sup>15</sup>.

# Droit d'auteur et coût des images

La numérisation et la mise en ligne de documents patrimoniaux implique également de prendre en compte la question des droits d'auteur, qui régit souvent les possiblités des institutions en termes de libre accès, et impacte par conséquent les projets, aussi bien du point de vue des exploitations possibles que de la publication de leurs résultats <sup>16</sup>.

Une œuvres originale est protégée au titre du droit d'auteur : ce droit comprend le droit moral, perpétuel et inaliénable, qui donne droit au respect de l'œuvre et du nom de son auteur, ainsi que le droit patrimonial, qui donne à l'auteur et ses ayants droit le droit d'autoriser ou non la reproduction et la diffusion de l'œuvre <sup>17</sup>. Les droits patrimoniaux

<sup>12.</sup> Certaines œuvres du projet sont disponibles sur Wikimedia, mais ces images en accès libre ne représentent qu'un fragment des œuvres numérisées dans le cadre du projet. De plus, les musées français sont très peu représentés dans cette sélection. Category :Google Art Project works by collection .

<sup>13.</sup> Akira Sakai, Digitizing Disparity in the Museum. The Object-Based Research in the Tokyo National Museum, août 2021, URL: https://universityheritage.eu/en/digitizing-disparity-in-the-museum-the-object-based-research-in-the-tokyo-national-museum/ (visité le 06/08/2023).

<sup>14.</sup> API Images d'Art

<sup>15.</sup> Isabelle Manca, « Les nouveaux défis des agences photographiques des musées »,  $Le\ Journal\ Des\ Arts$  (, juin 2018), URL : https://www.lejournaldesarts.fr/patrimoine/les-nouveaux-defis-des-agences-photographiques-des-musees-138076 (visité le 06/08/2023).

<sup>16.</sup> Olivier Jacquot, Décrire, transcrire et diffuser un corpus documentaire hétérogène : méthodes, formats, outils, Billet, nov. 2017, URL: https://bnf.hypotheses.org/2214 (visité le 06/08/2023).

<sup>17.</sup> Sophie Sepetjan, « Respecter le droit de la propriété littéraire et artistique », dans *Numériser et mettre en ligne*, dir. Thierry Claerr et Isabelle Westeel, Villeurbanne, 2017 (La Boîte à outils), p. 46-64, DOI: 10.4000/books.pressesenssib.426.

s'éteignent soixante-dix ans après la mort de l'auteur, et l'œuvre entre alors dans le domaine public <sup>18</sup>. Il n'existe pas d'exception au droit d'auteur pour une numérisation mise en ligne sur Internet <sup>19</sup>. Ces droits, qui s'appliquent à l'œuvre originale, ne sont pas nécessairement ceux qui nous intéressent dans le cadre d'un projet de recherche en histoire, dont les œuvres du corpus ont souvent rejoint le domaine public. La photographie d'une œuvre, cependant, peut faire l'objet du droit d'auteur, si celle-ci n'est pas considérée comme une reproduction servile.

Outre le droit d'auteur et les droits du photographe, les institutions peuvent exiger une redevance de réutilisation ou de prestation d'un service pour l'utilisation de leurs images, qui sert à couvrir, par exemple, les frais engagés pour la production du cliché, le traitement de la demande, ou la recherche iconographique <sup>20</sup>. Beaucoup d'institution, telles que la BnF et l'Inha (Institut national d'histoire de l'art) <sup>21</sup>, proposent des tarifications particulières pour des projets académiques, scientifiques ou non commerciaux, et n'appliquent un coût qu'en cas de demande de numérisation d'œuvres qui ne sont pas déjà numérisées. Les projets de recherche peuvent ainsi faire le choix de construire leurs corpus en prenant en compte les documents déjà disponibles, et mis en ligne sous licence libre.

# 2.1.2 Images et données ouvertes

#### **Licences Creative Commons**

Pour favoriser la libre circulation des images sur le Web, des licences ont été créées pour encadrer la réutilisation des numérisations. Dès 2001, les licences Creative Commons <sup>22</sup> sont créées avec la vocation de favoriser la diffusion et le parage des images dans un contexte numérique, en assouplissant notamment les droits de propriété intellectuelle pour s'adapter à ce nouveau cadre. Ces licences se basent sur un système de quatre options qu'il est possible de combiner pour créer six licences différentes. Ces options sont attribution (BY), non commercial (NC), sans modification (ND) et partage à l'identique (SD) <sup>23</sup>.

<sup>18.</sup> Il existe des cas particuliers, notamment pour les œuvres collectives ou les journaux, ainsi que pour les publications posthumes. Institut national d'histoire de l'art, *Guide Pratique Pour La Recherche et La Réutilisation Des Images d'œuvres d'art*, URL: https://www.inha.fr/\_resources/PDF/2021/2021\_LIVRET\_GUIDE-PRATIQUE\_web\_15062021.pdf.

<sup>19.</sup> S. Sepetjan, « Respecter le droit de la propriété littéraire et artistique »...

<sup>20.</sup> Institut national d'histoire de l'art, Guide Pratique Pour La Recherche et La Réutilisation Des Images d'œuvres d'art...

<sup>21.</sup> Martine Denoyelle, *A propos du coût des images d'œuvres patrimoniales*, Billet, juin 2021, URL: https://numrha.hypotheses.org/2142 (visité le 06/08/2023).

<sup>22.</sup> Ces licences ne sont plus reconnues par l'État français depuis 2016. Id., En savoir plus sur la licence Etalab et les autres licences, Billet, juin 2021, URL: https://numrha.hypotheses.org/2134 (visité le 06/08/2023).

<sup>23.</sup> Institut national d'histoire de l'art,  $Guide\ Pratique\ Pour\ La\ Recherche\ et\ La\ Réutilisation\ Des\ Images\ d'œuvres\ d'art...$ 

À partir de 2011, l'État français créée ses propres licences ouvertes, comme la licence unique Etalab, qui vise à « permettre et encourager la réutilisation des données publiques <sup>24</sup> ». Une deuxième version, publiée en 2017, se veut compatible avec la licence CC BY, c'est-à-dire une licence ouverte avec attribution de l'œuvre à son auteur.

Les données ouvertes sont un enjeu central des politiques culturelles : dans un contexte patrimonial, ces licences libres, conçues pour adapter les droits de propriété intellectuelle au contexte particulier du numérique, permettent ainsi la circulation, la diffusion et le partage de l'information. Il n'existe pas encore de cadre juridique international régissant l'utilisation des images produites par numérisation de collection patrimoniales, ainsi, les institutions sont soumises au droit spécifique du pays qui les abrite. En l'absence d'un encadrement global des pratiques, les utilisateurs – et notamment la communauté de la recherche – font face aux exceptions propres à chaque contexte national, qui représentent encore un obstacle. Une réflexion autour de ce cadre juridique international permettrait, en parallèle, d'harmosniser à une échelle globale les formats des données ouvertes <sup>25</sup>, pour en faciliter la réutilisation par les institutions et par les projets.

#### Enjeux techniques : images et métadonnées

Le document numérique obtenu à la suite d'une processus de numérisation est, en réalité, constitué de plusieurs fichiers répondant à des besoins différents pour la mise en ligne. Chacun de ces éléments représentent leurs propres enjeux techniques, dont la gestion impacte la qualité et l'exploitabilité des images mises en ligne à la suite d'entreprises de numérisation.

Les fichiers image issus d'un processus de numérisation peuvent avoir plusieurs formats <sup>26</sup> aux propriétés similaires mais différentes. En premier lieu, il est de bonne pratique de privilégier un format ouvert <sup>27</sup>, par opposition à un format propriétaire qui nécessite un logiciel spécifique pour être lu. Le choix d'un format ouvert permet d'assurer l'accessibilité des données produites. Les formats TIFF et JPEG sont favorisés dans le contexte de numérisation des collections patrimoniales, parce qu'ils permettent notamment la compression des fichiers <sup>28</sup> tout en maintenant la haute qualité des images <sup>29</sup>. Les choix effectués par les institutions impactent la qualité des numérisations produites qui, sur un plus long terme, impacte aussi bien la préservation des données, l'expérience des utilisateurs qui

<sup>24.</sup> M. Denoyelle, En savoir plus sur la licence Etalab et les autres licences...

<sup>25.</sup> Yaniv Benhamou, « Droit d'auteur et musées numériques »,  $Magazine\ de\ l'OMPI-3$  (juin 2016), URL : https://www.wipo.int/wipo\_magazine/fr/2016/03/article\_0005.html (visité le 06/08/2023).

<sup>26.</sup> Un format décrit la manière dont les informations sont organisées dans un fichier.

<sup>27.</sup> Camille Besse, Numérisation de Masse : Vers La Création d'un Nouvel Acteur de l'information. Le Projet Time Machine, Paris, 2019.

<sup>28.</sup> La compression sans perte s'effectue par identification et suppression des redondances, c'est-à-dire des pixels identiques. Cette méthode n'est pas irréversible, il est possible de décompresser le fichier.

 $<sup>29.\</sup> Digital\ Images,\ 2020,\ URL: \ https://livecode.byu.edu/images/DigitalImages.php (visité le <math display="inline">07/08/2023).$ 

consultent les images, et l'exploitabilité des fichiers par des projets. La question de la qualité des images est cruciale dans le cadre d'un projet de recherche en vision artificielle, puisque celle-ci a la possiblité d'impacter les performances de l'algorithme de utilisé, et d'affecter négativement les interprétations du modèle <sup>30</sup>.

Les fichiers images sont systématiquement accompagnés de métadonnées de diverses catégories, qui visent à décrire et identifier le document. Bien qu'il n'existe pas de standard international obligatoire concernant les métadonnées de numérisation, la standardisation des fichiers de métadonnées selon certains standards spécifiques permet de fluidifier la communication et les échanges entre institutions, dans une perspective interopérable qui permettrait de sortir des silos de données. Les métadonnées sont de plusieurs types : descriptives <sup>31</sup>, administratives <sup>32</sup>, structurelles <sup>33</sup>; elles ont pour vocation de gérer tous ces aspects du document numérique. Ces métadonnées sont cruciales pour l'identification et la classification des documents numérisés, mais aussi pour permettre la recherche et la navigation à travers les collections. Malgré leur importance, les différentes institutions ont une gestion profondément hétérogène de leurs métadonnées, sans uniformisation nationale ou internationale, et avec une disparité profonde entre les différents types d'institutions patrimoniales.

Pour pallier à cette disparité dans la gestion des métadonnées et au manque de standards pour le partage des images en ligne, des initiatives internationales ont vu le jour, visant à mettre fin à cette gestion en silo des données des institutions patrimoniales pour faciliter les échanges et la mise à disposition des données dans une optique de libre accès.

# 2.2 Le standard IIIF

#### 2.2.1 IIIF et les données ouvertes

#### Principes et objectifs

Le standard IIIF (International Image Interoperability Framework) <sup>34</sup> est une initiative collaborative lancée en 2011 par un groupement d'institutions <sup>35</sup> attachées à faciliter

<sup>30.</sup> Austin C. Bergstrom et David W. Messinger, « Image Quality and Computer Vision Performance : Assessing the Effects of Image Distortions and Modeling Performance Relationships Using the General Image Quality Equation », *Journal of Electronic Imaging*, 32 (mars 2023), p. 023018, DOI: 10.1117/1. JEI.32.2.023018.

<sup>31.</sup> Pour identifier le contenu du document numérique, le rattacher au document original.

<sup>32.</sup> Pour gérer les droits d'accès, préserver les informations techniques, suivre les modifications du fichier et garantir son intégrité.

<sup>33.</sup> Pour rattacher les fichiers entre eux et reconstituer la structure du document.

<sup>34.</sup> IIIF

<sup>35.</sup> Les collaborateurs à l'initiative du projet sont la British Library, la BnF, Stanford University, les Bodleian Libraries, la Bibliothèque nationale de Norvège, la Bibliothèque nationale de Los Alamos et Cornell University.

la diffusion sur le Web des ressources iconographiques des collections patrimoniales <sup>36</sup>. La volonté de développement de ce standard provient du constat que, malgré la nécessité d'un accès global aux images numériques pour la transmission du patrimoine culturel, un grand nombre de ces ressources restent, sur Internet, isolées dans des silos d'information dont l'accès n'est possible que par des applications spécifiques à chaque institution <sup>37</sup>, rendant difficile le partage et la mise en commun des ressources.

De cette observation est née la volonté de créer un outil proposant des méthodes standardisées de partage sur le Web des images et de leurs métadonnées, pour toute institution qui souhaiterait partager numériquement ses collections. IIIF propose ainsi un standard dont les fonctionnalités vont au-delà de celles d'un navigateur, capable d'afficher des formats libres d'image <sup>38</sup>, sans proposer plus d'interaction avec les images servies <sup>39</sup>. IIIF propose ainsi des outils interopérables, libres d'accès, permettant notamment de zoomer en profondeur sur les images, d'y appliquer des traitements visuels simples, de reconstruire la structure du document ou de les annoter.

Pour assurer ces fonctionnalités, IIIF s'appuie sur deux API : l'API Image et l'API Présentation. Ces API sont le socle du standard, elles en assurent la cohérence afin que les images puissent être partagées de manière fluide entre les institutions et projets. Le cœur du standard IIIF, qui fait tout son intérêt dans le contexte décrit précédemment du partage des images sur le Web, est en effet l'interopérabilité : IIIF assure ainsi la portabilité entre les visualiseurs, pour permettre une transmission réellement fluide de l'information.

#### Les API IIIF

Le fonctionnement du standard IIIF s'appuie sur deux éléments essentiels : l'envoi des images depuis les serveurs, et leur visualisation.

L'API Image définit les spécifications pour un service renvoyant une image en réponse à une requête HTTP (Hypertext Transfer Protocol) ou HTTPS (Hypertext Transfer Protocol Secure) : à partir d'une URI (Uniform Resource Identifier) valide, l'image peut être affichée dans un visualiseur, ou dans un navigateur. L'URI peut spécifier, dans sa requête, la région, la taille, la rotation, la qualité ou le format de l'image demandée, suivant des instructions spécifiques prédéfinies par le standard <sup>40</sup>. En ajustant les paramètres, l'utilisateur peut ainsi obtenir une image qu'il peut modifier en accord avec ses besoins sans passer par un éditeur spécifique. L'API Image, développée pour des clients tels que les applications

<sup>36.</sup> Tom Cramer, The International Image Interoperability Framework (IIIF): Laying the Foundation for Common Services, Integrated Resources and a Marketplace of Tools for Scholars Worldwide, déc. 2011, URL: https://www.cni.org/topics/information-access-retrieval/international-image-interoperability-framework (visité le 08/08/2023).

<sup>37.</sup> *Ibid*.

<sup>38.</sup> IIIF propose également, depuis 2020, un service dédié aux fichiers vidéo, que nous n'abordons pas dans ce mémoire car les projets étudiés portent tous sur des images fixes.

<sup>39.</sup> How It Works, URL: https://iiif.io/get-started/how-iiif-works/ (visité le 08/08/2023).

<sup>40.</sup>  $Image\ API\ 3.0,\ URL: https://iiif.io/api/image/3.0/$  (visité le 08/08/2023).

d'institutions patrimoniales, peut être implémentée sans l'API Présentation : seule, elle permet notamment un zoom rapide et profond sur des images en très haute résolution.

L'API Présentation permet d'introduire des fonctionnalités plus vastes en termes d'informations liées aux images : par le biais d'un manifeste au format JSON (JavaScript Object Notation), elle attache aux images des métadonnées descriptives, administratives et structurelles qui définissent la manière dont elles seront présentées dans un visualiseur. Le manifeste permet notamment de rassembler en un fichier les différents éléments d'un objet IIIF <sup>41</sup>, et notamment les séries d'images <sup>42</sup>, tout en gérant également leur ordre dans le document numérique. Le manifeste contient généralement des informations d'identification de l'objet original <sup>43</sup>, et peut être enrichi d'annotations sur l'objet ou son contenu <sup>44</sup>.

Pour afficher les images et les informations liées, il existe une multitude de visualiseurs <sup>45</sup> aux fonctionnalités différentes, tous compatibles avec tous les manifestes IIIF, quelle que soit leur institution d'origine. Ainsi, les ressources produites par les institutions peuvent être consultées par le biais d'outils libres, accessibles à tous. Pour aller au-delà des fonctionnalités proposées par les deux API centrales du standard, quatre autres API ont été développées, pour gérer d'autres besoins liés à mise à disposition d'images tout en respectant des principes standardisés <sup>46</sup>.

#### Anatomie d'un manifeste

Pour constituer les éléments retournées par les API IIIF, il existe un modèle de données spécifique, qui assure la caractérisation des objets selon des normes communes, qui permettent de conserver l'interopérabilité du standard. Il existe ainsi des types de ressources, ou classes, précisément définies, avec une hiérarchie fixe (fig. 2.1), qui permettent de décrire les objets numérisés au format JSON.

Un manifeste est un fichier au format JSON. Du point de vue de la donnée, la classe *Manifest* permet de décrire un objet composé, une œuvre dans sa totalité : elle contient ainsi un ensemble de métadonnées descriptives la concernant (titre, auteur, institution de conservation, licence), et permet, si nécessaire, de reconstituer la structure de l'objet à partir des *Canvases*.

Le Canvas est un conteneur de niveau inférieur au Manifest, qui permet de représenter une vue spécifique d'un objet, et les métadonnées qui y sont associées. Si nécessaire, un élément de niveau supérieur peut exister entre les Canvases et le Manifest : il s'agit des Ranges, qui permettent de décrire une séquence de Canvases.

<sup>41.</sup> How It Works...

<sup>42.</sup> Cette fonctionnalité est particulièrement intéressante pour les numérisations d'ouvrages, puisqu'elle permet de regrouper en un fichier toutes les pages numérisées.

<sup>43.</sup> On retrouve notamment le titre, l'auteur, l'institution de conservation, le numéro d'inventaire ou la cote, et les informations sur les droits de diffusion.

<sup>44.</sup> Presentation API 3.0, URL: https://iiif.io/api/presentation/3.0/ (visité le 08/08/2023).

<sup>45.</sup> IIIF Viewers, URL: https://iiif.io/get-started/iiif-viewers/ (visité le 08/08/2023).

<sup>46.</sup> How It Works...

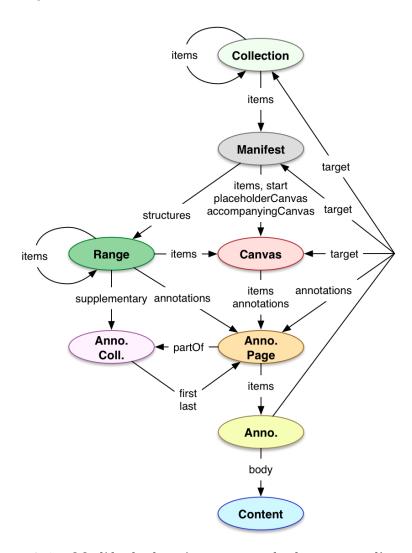


FIGURE 2.1 – Modèle de données IIIF pour la description d'un objet

Il existe, à un niveau supérieur au *Manifest*, une classe *Collection*, qui assure une plus grande flexibilité du modèle pour les projets qui souhaiteraient réunir plusieurs objets dans une catégorie plus large. Une *Collection* peut représenter une liste de *Manifests*, ou une liste de *Collections*, permettant ainsi de regrouper des objets ou groupes d'objets selon un cadre défini, qui facilite la navigation dans un ensemble restreint de ressources liées <sup>47</sup>.

Pour un manifeste ne contenant que des images et leurs métadonnées, ces éléments suffisent à construire un fichier cohérent et fonctionnel, qui pourra être lu par un visualiseur IIIF.

Pour annoter les images d'un manifeste, il existe une série de types de ressource additionnels qui contiennent les annotations selon une hiérarchie précise, et les rattache à un Canvas spécifique. L'Annotation Page contient une liste ordonnée d'Annotations pour un Canvas : pour annoter un manifeste, il existe donc autant d'Annotation Pages qu'il existe de Canvases annotés.

<sup>47.</sup> Presentation API 3.0...

La classe Annotation fait le lien entre le contenu de l'annotation (Content) et le Canvas 48 : ce type de ressource permet d'assurer l'interopérabilité du modèle, puisqu'elle permet l'alignement des annotations et des images, y compris dans le contexte d'annotations produites par un utilisateur différent du créateur du manifeste. Ainsi, ce modèle de données permet la collaboration entre plusieurs utilisateurs à partir d'un manifeste produit par une institutions, et rend possible la réutilisation des images comme des manifestes dans des projets ultérieurs, avec la fluidité d'un modèle partagé, standard, qui ne nécessite aucun effort d'alignement entre institutions.

## 2.2.2 IIIF, un modèle universel?

### Limites de l'interopérabilité du standard

IIIF est ainsi pensé comme un standard universel permettant aux institutions et aux projets qui le souhaitent de partager leurs ressources, de les mettre à disposition en assurant la possibilité de leur réutilisation : dans une optique de science ouverte, IIIF permet de partager aisément les résultats de projets de recherche impliquant des images.

Cependant, malgré l'existence d'un modèle de données standard pour la description des objets, IIIF présente des limites dans son universalité. En effet, malgré son cadre construit pour assurer l'interopérabilité des manifestes, le modèle n'est en pratique pas employé de la même manière par toutes les institutions, et nécessite donc une adaptation des développements faits autour de IIIF pour prendre en compte ces exceptions. Nous constatons, par exemple, que si les ressources images sont supposées être intégrées au manifeste dans un conteneur Canvas, certaines institutions – comme la bibliothèque univeristaire de Yale – utilisent plutôt des Items (fig. 2.2), modifiant ainsi profondément la structure du manifeste IIIF tout en conservant un fichier lisible par les visualiseurs. L'application du standard varie ainsi d'une institution à l'autre, sans altérer le fonctionnement des outils de base de IIIF, mais en provoquant cependant une déperdition de son universalité pour des projets qui souhaiteraient développer des outils autour de ces manifestes.

Dans un projet reposant sur l'exploitation d'images d'objets patrimoniaux, tels que les projets décrits dans ce mémoire, il est ainsi nécessaire de prendre en compte ces exceptions techniques : dans le cadre du projet EIDA, la récupération des images est effectuée par un algorithme spécifique <sup>49</sup>, qui parse un manifeste IIIF déposé par un utilisateur dans l'application du projet et en extrait des fichiers images pour les enregistrer. Dans le développement de cet algorithme, il a ainsi été nécessaire de prendre en compte les exceptions possibles, pour ne pas créer d'erreur en cas de dépôt d'un manifeste à la structure différente.

<sup>48.</sup> Ibid.

<sup>49.</sup>  $\it Hif-Downloader$ , URL: https://github.com/Segolene-Albouy/iiif-downloader/tree/main (visité le 09/08/2023).

(a) Manifeste IIIF de la bibliothèque universitaire de Dresde avec Canvases

(b) Manifeste IIIF de la bibliothèque universitaire de Yale avec Items

Figure 2.2 – Comparatif des ressources contenant les images de deux manifestes IIIF

## Implémentation de IIIF: un réflexe global?

Pour les projets de recherche exploitant des images respectant le standard IIIF, il se pose la question des institutions ayant fait le choix de gérer leurs images différemment. En effet, si de nombreuses institutions ont adopté le standard et mis en ligne des centaines de millions d'images compatibles depuis la naissance de l'initiative <sup>50</sup>, il n'est ni obligatoire ni systématique, et il reste ainsi un nombre certain d'établissements qui gèrent leurs images avec des outils techniques différents, et restent ainsi exclus du standard. Les musées, notamment, et particulièrement les musées hors Amérique du Nord, exploitent encore peu les possibilités offertes par IIIF en termes de partage des images <sup>51</sup>, et restent en marge de cette initiative de facilitation de la mise en commun et de l'exploitation des ressources iconographiques.

Il n'est cependant pas envisageable, dans le cadre d'un projet de recherche, d'exclure totalement les sources provenant d'institutions n'utilisant pas le standard IIIF: il est donc nécessaire, dans le développement d'outils numériques pour la gestion des images, de prendre en compte ces sources aux formats différents, qu'il faut traiter pour les rendre exploitable de la même manière que le sont les images extraites de manifestes IIIF. Ainsi, dans la chaîne de traitement des images, une réflexion doit être menée pour l'intégration

<sup>50.</sup> Gavin Mallory, IIIF for Museums, Explained, juill. 2019, URL: https://blog.cogapp.com/iiif-for-museums-explained-49fd0560e1ba (visité le 09/08/2023).

<sup>51.</sup> IIIF for Museums in France, juill. 2023, URL: https://www.culture.gouv.fr/en/Thematic/Museums/Pour-les-professionnels/Network/IIIF-for-museums-in-France (visité le 09/08/2023).

d'autres formats, tels que les PDF pour les numérisations d'ouvrages, ou les fichiers image indépendants. Malgré la fluidité du traitement des sources permise par l'existence d'un standard, il est ainsi nécessaire de réfléchir à des solutions techniques au-delà des limites de ce dernier, pour ne pas exclure des *corpora* les sources numérisées présentant un intérêt pour la recherche.

Dans un projet de recherche en vision artificielle, l'utilisation du standard IIIF permet, d'une part, la constitution aisée d'un corpus d'images, qu'il est possible de récupérer directement sur les sites des institutions à l'aide des API : le standard IIIF fluidifie fortement les échanges et la réutilisation des documents numérisés, et permet de construire un outil générique pour le traitement de sources numériques provenant d'institutions diverses. Il reste cependant de nombreux cas où une chaîne de traitement parallèle doit être développée, pour pallier à l'absence d'implémentation du standard dans certaines institutions. D'autre part, l'utilisation du standard IIIF pour la publication en ligne des données du projet permet également d'envisager leur réutilisation future par d'autres initiatives, en s'assurant de l'interopérabilité des résultats produits, dans une démarche de science ouverte.

# Corpus historiques et jeux de données pour l'apprentissage machine

#### 3.1 Dimensions et cadre

#### 3.1.1 La tentative de l'exhaustivité

Sous-sous-section 1

Sous-sous-section 2

#### 3.1.2 Automatiser le traitement de gros corpus

Sous-sous-section 1

Sous-sous-section 2

#### 3.2 Annotations et qualité des données

#### 3.2.1 Objectifs scientifiques et possibilités numériques

Sous-sous-section 1

Sous-sous-section 2

#### 3.2.2 Définir les pratiques

Sous-sous-section 1

# Deuxième partie

De l'image à l'objet : intégrer l'apprentissage profond au traitement des sources historiques

# Principes et méthodes de l'apprentissage profond

#### 4.1 Réseaux de neurones et computer vision

#### 4.1.1 Des « neurones » pour le machine learning

Sous-sous-section 1

Sous-sous-section 2

#### 4.1.2 « Voir », comprendre et traiter les images

Sous-sous-section 1

Sous-sous-section 2

# 4.2 Modèles de vision *off-the-shelf* : outils libres pour la détection d'objets

#### 4.2.1 YOLOv5, docExtractor et autres modèles

Sous-sous-section 1

Sous-sous-section 2

#### 4.2.2 Entraı̂nement et fine-tuning

Sous-sous-section 1

# L'interface entre chercheurs et algorithme : construire une plateforme pour la détection

- 5.1 Architecture de l'application : fonctionnalités et outils
- 5.1.1 Une interface pour le dépôt des sources

Sous-sous-section 1

Sous-sous-section 2

5.1.2 Décrire les sources

Sous-sous-section 1

Sous-sous-section 2

5.1.3 Images et objets détectés : une nouvelle source?

Sous-sous-section 1

Sous-sous-section 2

- 5.2 Créer un outil open source : penser une application réutilisable
- 5.2.1 De VHS à EiDA : adapter un modèle de données

Sous-sous-section 1

Sous-sous-section 2

5.2.2 Construire une application réutilisable

Cours government 1

# Intégrer l'apprentissage profond aux pratiques des chercheurs : le workflow de traitement des sources

#### 6.1 Annoter sur un GPU: extractorAPI

#### 6.1.1 Architecture du système

Sous-sous-section 1

Sous-sous-section 2

#### 6.1.2 Cahier des charges et analyse des besoins

Sous-sous-section 1

Sous-sous-section 2

#### 6.1.3 Programmation modulaire et open source

Sous-sous-section 1

Sous-sous-section 2

#### 6.2 De la numérisation à l'annotation

#### 6.2.1 Workflow d'annotation

Sous-sous-section 1

Sous-sous-section 2

#### 6.2.2 Échanges et transformation des données

Sous-sous-section 1

Sous-sous-section 2

C 2 2 Interfered diameteries

# Troisième partie

Perspectives pour le traitement des sources : vers un outil pour l'édition et la recherche

# Éditer des diagrammes : vectorisation et édition critique

#### 7.1 Édition critique des diagrammes astronomiques

#### 7.1.1 Historique

Sous-sous-section 1

Sous-sous-section 2

#### 7.1.2 Éditer les diagrammes en format numérique

Sous-sous-section 1

Sous-sous-section 2

# 7.2 De l'image aux vecteurs : la vision artificielle pour l'édition numérique

#### 7.2.1 Automatiser la transcription

Sous-sous-section 1

Sous-sous-section 2

#### 7.2.2 Données d'entraînement et annotations pour la vectorisation

Sous-sous-section 1

Sous-sous-section 2

#### 7.2.3 Diagrammes en SVG

Sous-sous-section 1

# Regroupement par similarité et clustering

#### 8.1 Similarity retrieval et navigation des corpus

#### 8.1.1 Principe et méthodes

Sous-sous-section 1

Sous-sous-section 2

#### 8.1.2 Fouiller des corpus par l'image

Sous-sous-section 1

Sous-sous-section 2

#### 8.2 Le *clustering* comme outil pour les chercheurs

#### 8.2.1 Sous-section 1

Sous-sous-section 1

Sous-sous-section 2

#### 8.2.2 Sous-section 2

Sous-sous-section 1

Sous-sous-section 2

#### 8.2.3 Sous-section 3

Sous-sous-section 1

Étudier et exploiter les résultats automatiques : limites et perspectives pour les sciences historiques

#### 9.1 Titre section 1

#### 9.1.1 Sous-section1

Sous-sous-section 1

Sous-sous-section 2

#### 9.1.2 Sous-section 2

Sous-sous-section 1

Sous-sous-section 2

#### 9.1.3 Sous-section 3

Sous-sous-section 1

Sous-sous-section 2

#### 9.2 Titre section 2

#### 9.2.1 Sous-section1

Sous-sous-section 1

Sous-sous-section 2

#### 9.2.2 Sous-section 2

# Conclusion

# Annexes

### Liste des acronymes

Application Programming Interface. 15, 19, 20, 24 CSV Comma-separated values. 6 DIPS DISHAS Interactive Parameter Squeezer. 5 DISHAS Digital Information System for the History of Astral Sciences. 4–6, 10 DISHAS Table Interface. 5 EIDA Editing and analysing hIstorical astronomical Diagrams with Artificial intelligence. 3-7, 10-14, 22HTML HyperText Markup Language. 6 HTR Handwritten Text Recognition. 6 HTTPS Hypertext Transfer Protocol Secure. 19 HTTP Hypertext Transfer Protocol. 19 International Image Interoperability Framework. 18–24 IMAGINE Laboratoire d'Informatique Gaspard Monge. 6, 7 INHA Institut national d'histoire de l'art. 16 ISCD Institut des sciences du calcul et des données. 6 JSON JavaScript Object Notation. 20 SYRTE Systèmes de Référence Temps-Espace. 6 Uniform Resource Identifier. 19 Vision artificielle et analyse Historique de la circulation de l'illustration Scientifique. 6, 7

Rmn-Grand Palais Réunion des musées nationaux-Grand Palais. 14, 15

XML eXtensible Markup Language. 6

BnF Bibliothèque nationale de France. 13, 16, 18

48 Acronymes

# Table des matières

$\mathbf{R}$	ésum	ıé		iii
$\mathbf{R}$	emer	ciemer	nts	v
In	trodi	uction		xi
I pa			ire un corpus de numérisations pour le traitement artificielle	1
1	Le j	projet	EiDA	3
	1.1	Conte	xte et objectifs du projet	3
		1.1.1	Un projet de recherche en humanités numériques	3
		1.1.2	Avant EiDA : le projet DISHAS	5
		1.1.3	Acteurs du projet	6
	1.2	Source	es primaires	8
		1.2.1	L'astronomie ptoléméenne : naissance et diffusion	8
		1.2.2	Les diagrammes	10
2	Ima	iges et	interopérabilité	13
	2.1	L'imag	ge comme source	13
		2.1.1	Construire un corpus d'images : enjeux et méthodes	13
		2.1.2	Images et données ouvertes	16
	2.2	Le sta	ndard IIIF	18
		2.2.1	IIIF et les données ouvertes	18
		2.2.2	IIIF, un modèle universel?	22
3	Cor	pus hi	storiques et jeux de données	25
	3.1	Dimer	nsions et cadre	25
		3.1.1	La tentative de l'exhaustivité	25
		3.1.2	Automatiser le traitement de gros corpus	25
	2.9	Annot	entions et qualité des dennées	25

		3.2.1	Objectifs scientifiques et possibilités numériques	25
		3.2.2	Définir les pratiques	25
II tr			age à l'objet : intégrer l'apprentissage profond au des sources historiques	ı 27
4	L'a <sub>I</sub>	prenti	issage profond	29
	4.1	Réseau	ux de neurones et computer vision	29
		4.1.1	Des « neurones » pour le machine learning	29
		4.1.2	« Voir », comprendre et traiter les images	29
	4.2	Modèl	es de vision off-the-shelf	29
		4.2.1	YOLOv5, docExtractor et autres modèles	29
		4.2.2	Entraı̂nement et fine-tuning	29
5	L'in	terface	e entre chercheurs et algorithme	31
	5.1	Archit	ecture de l'application	32
		5.1.1	Une interface pour le dépôt des sources	32
		5.1.2	Décrire les sources	32
		5.1.3	Images et objets détectés : une nouvelle source?	32
	5.2	Créer	un outil open source : penser une application réutilisable	32
		5.2.1	De VHS à EiDA : adapter un modèle de données	32
		5.2.2	Construire une application réutilisable	32
6	Dee	ep lear	ning et pratiques des chercheurs	33
	6.1	Annot	er sur un GPU : extractorAPI	34
		6.1.1	Architecture du système	34
		6.1.2	Cahier des charges et analyse des besoins	34
		6.1.3	Programmation modulaire et open source	34
	6.2	De la	numérisation à l'annotation	34
		6.2.1	Workflow d'annotation	34
		6.2.2	Échanges et transformation des données	34
		6.2.3	Interface d'annotation	34
	6.3	Média	tion et documentation	34
		6.3.1	Séminaire DH et échanges avec les chercheurs	34
		6.3.2	Documentation et Wiki : penser le réemploi du code	34

#### III Perspectives pour le traitement des sources : vers un outil

po	our	l'éditi	ion et la recherche	35
7	Édi	ter des	s diagrammes	37
	7.1	Éditio	on critique des diagrammes astronomiques	. 38
		7.1.1	Historique	. 38
		7.1.2	Éditer les diagrammes en format numérique	. 38
	7.2	De l'in	mage aux vecteurs	. 38
		7.2.1	Automatiser la transcription	. 38
		7.2.2	Données d'entraı̂nement et annotations pour la vectorisation	. 38
		7.2.3	Diagrammes en SVG	. 38
8	Reg	groupe	ment par similarité et <i>clustering</i>	39
	8.1	Simila	arity retrieval et navigation des corpus	. 40
		8.1.1	Principe et méthodes	. 40
		8.1.2	Fouiller des corpus par l'image	. 40
	8.2	Le clu	ustering comme outil pour les chercheurs	. 40
		8.2.1	Sous-section 1	. 40
		8.2.2	Sous-section 2	. 40
		8.2.3	Sous-section 3	. 40
9	Exp	oloiter	les résultats automatique	41
	9.1	Titre	section 1	. 42
		9.1.1	Sous-section1	. 42
		9.1.2	Sous-section 2	. 42
		9.1.3	Sous-section 3	. 42
	9.2	Titre	section $2 \ldots \ldots \ldots \ldots \ldots$	. 42
		9.2.1	Sous-section1	. 42
		9.2.2	Sous-section 2	. 42
		9.2.3	Sous-section 3	. 42
Co	onclu	ısion		43
$\mathbf{A}$	nne	xes		47
A	crony	ymes		47
Ta	able o	des ma	atières	49