

ÉCOLE NATIONALE DES CHARTES

Jade Norindr

licenciée ès lettres

Le traitement des sources historiques par la vision artificielle

L'exemple des manuscrits d'astronomie de tradition ptoléméenne

Mémoire pour le diplôme de master

« Technologies numériques appliquées à l'histoire »

2023

Résumé

Résumé

Mots-clés : histoire des sciences ; diagrammes astronomiques ; images ; *machine learning* ; vision artificielle ; apprentissage profond ; YOLOv5 ; réseau de neurones artificiels ; automatisation ; Python ; programmation modulaire ; IIIF ; API ; Flask.

Informations bibliographiques : Jade Norindr, *Le traitement des sources historiques par la vision artificielle. L'exemple des manuscrits d'astronomie de tradition ptoléméenne*, mémoire de master « Technologies numériques appliquées à l'histoire », dir. Maxime Challon, École nationale des chartes, 2023.

Remerciements

Bibliographie

- API de La RMN-Grand Palais*, URL : <https://api.art.rmngp.fr/> (visité le 10/08/2023).
- BAUJARD (Corinne), « Numérisation du patrimoine culturel et stratégie managériale des musées », *Management des technologies organisationnelles*–7 (févr. 2017), p. 69-78, URL : <https://www.cairn.info/revue-management-des-technologies-organisationnelles-2017-2-page-69.htm> (visité le 06/08/2023).
- BENHAMOU (Yaniv), « Droit d’auteur et musées numériques », *Magazine de l’OMPI*–3 (juin 2016), URL : https://www.wipo.int/wipo_magazine/fr/2016/03/article_0005.html (visité le 06/08/2023).
- BERGSTROM (Austin C.) et MESSINGER (David W.), « Image Quality and Computer Vision Performance : Assessing the Effects of Image Distortions and Modeling Performance Relationships Using the General Image Quality Equation », *Journal of Electronic Imaging*, 32 (mars 2023), p. 023018, DOI : 10.1117/1.JEI.32.2.023018.
- BESSE (Camille), *Numérisation de Masse : Vers La Création d’un Nouvel Acteur de l’information. Le Projet Time Machine*, Paris, 2019.
- BÜTTNER (Jochen), MARTINETZ (Julius), EL-HAJJ (Hassan) et VALLERIANI (Matteo), « CorDeep and the Sacrobosco Dataset : Detection of Visual Elements in Historical Documents », *Journal of Imaging*, 8–10 (oct. 2022), p. 285, DOI : 10.3390/jimaging8100285.
- Category :Google Art Project Works by Collection - Wikimedia Commons*, URL : https://commons.wikimedia.org/wiki/Category:Google_Art_Project_works_by_collection (visité le 10/08/2023).
- CHAGUÉ (Alix) et CLÉRICE (Thibault), *HTR-United*, URL : <https://htr-united.github.io/index.html> (visité le 10/08/2023).
- CLAERR (Thierry) et WESTEEL (Isabelle), « Mode d’emploi », dans *Numériser et mettre en ligne*, Villeurbanne, 2017 (La Boîte à outils), p. 7-18, DOI : 10.4000/books.pressesenssib.419.
- CorDeep*, URL : <https://cordeep.mpiwg-berlin.mpg.de/> (visité le 10/08/2023).
- Corpus*, URL : <https://vhs.hypotheses.org/corpus> (visité le 09/08/2023).
- CRAMER (Tom), *The International Image Interoperability Framework (IIIF) : Laying the Foundation for Common Services, Integrated Resources and a Marketplace of Tools for Scholars Worldwide*, déc. 2011, URL : <https://www.cni.org/topics/>

- information-access-retrieval/international-image-interopability-framework (visité le 08/08/2023).
- DENOYELLE (Martine), *A propos du coût des images d'œuvres patrimoniales*, Billet, juin 2021, URL : <https://numrha.hypotheses.org/2142> (visité le 06/08/2023).
- *En savoir plus sur la licence Etalab et les autres licences*, Billet, juin 2021, URL : <https://numrha.hypotheses.org/2134> (visité le 06/08/2023).
- Digital Images*, 2020, URL : <https://livecode.byu.edu/images/DigitalImages.php> (visité le 07/08/2023).
- EdIter et analyser les Diagrammes astronomiques historiques avec l'intelligence Artificielle*, URL : <https://anr.fr/Projet-ANR-22-CE38-0014> (visité le 10/08/2023).
- Enhancing Heritage Image Databases*, URL : <https://anr.fr/Project-ANR-17-CE23-0008> (visité le 10/08/2023).
- Europeana*, URL : <https://www.europeana.eu/fr> (visité le 10/08/2023).
- EVANS (James), « History of Astronomy », dans *Encyclopedia Britannica*, URL : <https://www.britannica.com/science/astronomy/Ancient-Greece> (visité le 03/08/2023).
- Gallica*, URL : <https://gallica.bnf.fr/> (visité le 10/08/2023).
- Google Arts & Culture*, URL : <https://artsandculture.google.com/> (visité le 10/08/2023).
- Jeffrey F. Hamburger, David J. Roxburgh et Linda Safran (éd.), *The Diagram as Paradigm : Cross-Cultural Approaches*, Cambridge, MA, 2022 (Dumbarton Oaks Byzantine Symposia and Colloquia).
- Historical Navigation — DISHAS Project — Astronomical Table in Database*, URL : <https://dishas.obspm.fr/historical-navigation> (visité le 10/08/2023).
- Home — DISHAS Project — Astronomical Table in Database*, URL : <https://dishas.obspm.fr/> (visité le 10/08/2023).
- How It Works*, URL : <https://iiif.io/get-started/how-iiif-works/> (visité le 08/08/2023).
- IIIF for Museums in France*, juill. 2023, URL : <https://www.culture.gouv.fr/en/Thematic/Museums/Pour-les-professionnels/Network/IIIF-for-museums-in-France> (visité le 09/08/2023).
- IIIF Viewers*, URL : <https://iiif.io/get-started/iiif-viewers/> (visité le 08/08/2023).
- Iiif-Downloader*, URL : <https://github.com/Segolene-Albouy/iiif-downloader/tree/main> (visité le 09/08/2023).
- Image API 3.0*, URL : <https://iiif.io/api/image/3.0/> (visité le 08/08/2023).
- ImageNet*, URL : <https://www.image-net.org/> (visité le 10/08/2023).
- INSTITUT NATIONAL D'HISTOIRE DE L'ART, *Guide Pratique Pour La Recherche et La Réutilisation Des Images d'œuvres d'art*, URL : https://www.inha.fr/_resources/PDF/2021/2021_LIVRET_GUIDE-PRATIQUE_web_15062021.pdf.

- JACQUOT (Olivier), *Décrire, transcrire et diffuser un corpus documentaire hétérogène : méthodes, formats, outils*, Billet, nov. 2017, URL : <https://bnf.hypotheses.org/2214> (visité le 06/08/2023).
- JARDINE (Boris) et JARDINE (Nicholas), « Critical Editing of Early-Modern Astronomical Diagrams », *Journal for the History of Astronomy*, 41–3 (août 2010), p. 393-414, DOI : 10.1177/002182861004100307.
- JONES (Alexander Raymond), « Ptolemy », dans *Encyclopedia Britannica*, URL : <https://www.britannica.com/biography/Ptolemy> (visité le 03/08/2023).
- KLINKE (Harald), « Big Image Data within the Big Picture of Art History », *International Journal for Digital Art History-2* (oct. 2016), DOI : 10.11588/dah.2016.2.33527.
- LIN (Xinyu), ZHOU (Yingjie), LIU (Yipeng) et ZHU (Ce), *A Comprehensive Review of Image Line Segment Detection and Description : Taxonomies, Comparisons, and Challenges*, avr. 2023, DOI : 10.48550/arXiv.2305.00264, arXiv : 2305.00264 [cs].
- MALLORY (Gavin), *IIIF for Museums, Explained*, juill. 2019, URL : <https://blog.cogapp.com/iiif-for-museums-explained-49fd0560e1ba> (visité le 09/08/2023).
- MANCA (Isabelle), « Les nouveaux défis des agences photographiques des musées », *Le Journal Des Arts* (, juin 2018), URL : <https://www.lejournaldesarts.fr/patrimoine/les-nouveaux-defis-des-agences-photographiques-des-musees-138076> (visité le 06/08/2023).
- MOIRAGHI (Eleonora) et MOREUX (Jean-Philippe), *Explorer des corpus d'images. L'IA au service du patrimoine*, Billet, avr. 2018, URL : <https://bnf.hypotheses.org/2809> (visité le 06/08/2023).
- MONNIER (Tom), VINCENT (Elliot), PONCE (Jean) et AUBRY (Mathieu), *Unsupervised Layered Image Decomposition into Object Prototypes*, août 2021, DOI : 10.48550/arXiv.2104.14575, arXiv : 2104.14575 [cs].
- MONNIERT, *docExtractor*, juill. 2023, URL : <https://github.com/monniert/docExtractor> (visité le 10/08/2023).
- Presentation API 3.0*, URL : <https://iiif.io/api/presentation/3.0/> (visité le 08/08/2023).
- RICHARD (Michel), « Le programme de numérisation de la Bibliothèque de France », *Bulletin des bibliothèques de France-3* (1993), p. 53-63, URL : <https://bbf.enssib.fr/consulter/bbf-1993-03-0053-007> (visité le 06/08/2023).
- ROUSSEAU (Jean-Jacques), *Epicycles de Ptolémée*, URL : <http://ressources.univ-lemans.fr/AccesLibre/UM/Pedago/physique/02/divers/ptolemee.html> (visité le 05/08/2023).
- SAKAI (Akira), *Digitizing Disparity in the Museum. The Object-Based Research in the Tokyo National Museum*, août 2021, URL : <https://universityheritage.eu/en/>

digitizing-disparity-in-the-museum-the-object-based-research-in-the-tokyo-national-museum/ (visité le 06/08/2023).

SEPETJAN (Sophie), « Respecter le droit de la propriété littéraire et artistique », dans *Numériser et mettre en ligne*, dir. Thierry Claerr et Isabelle Westeel, Villeurbanne, 2017 (La Boîte à outils), p. 46-64, DOI : 10.4000/books.pressesenssib.426.

STRIEN (Daniel van), BEELEN (Kaspar), WEVERS (Melvin), SMITS (Thomas) et McDONOUGH (Katherine), « Computer Vision for the Humanities : An Introduction to Deep Learning for Image Classification (Part 1) », *Programming Historian* (, août 2022), URL : <https://programminghistorian.org/en/lessons/computer-vision-deep-learning-pt1> (visité le 10/08/2023).

TRISTANDOT, *tableTranscriber : An Automatic Pipeline for Astronomical Tables Transcription*, oct. 2022, URL : <https://github.com/tristandot/tableTranscriber> (visité le 10/08/2023).

Introduction

Première partie

Construire un corpus de numérisations pour le traitement par vision artificielle

Chapitre 1

Le projet EiDA

Cette partie a pour objectif de revenir sur le contexte institutionnel du projet EIDA (*Editing and analysing hIstorical astronomical Diagrams with Artificial intelligence*), projet de recherche mené à l’Observatoire de Paris par l’équipe d’histoire des science du laboratoire SYRTE. Ce projet a pour sujet d’étude les diagrammes astronomiques de tradition ptoléméenne : cette partie vise ainsi à contextualiser d’un point de vue historique le corpus du projet, et à en expliciter les bornes chronologiques et géographiques.

1.1 Contexte et objectifs du projet

1.1.1 Un projet de recherche en humanités numériques

Cadre du projet

Les sciences astronomiques se développent, à travers les siècles, à l’intersection de besoins et de questionnements divers auxquels elles tentent de répondre. Des besoins politiques aux besoins religieux, ces disciplines existent au cœur de contextes culturels, géographiques, historiques variés et interconnectés, et produisent, dans le cadre de leur pratique, des supports éclectiques qui témoignent de l’évolution des idées, et des conceptions du monde et de l’univers. Les manuscrits et imprimés produits dans le cadre des sciences astronomiques, pour répondre aux besoins de ceux qui les emploient, comportent des tables, des textes et des diagrammes d’une grande richesse, à l’image de la diversité de leurs contextes de production et de leurs utilisations.

Le projet EIDA¹, ayant pour vocation d’analyser ces sources dans le cadre de l’histoire des sciences, s’intéresse plus spécifiquement aux diagrammes astronomiques, en tant que patrimoine visuel et supports pour la circulation des idées et théories astronomiques et mathématiques. L’étude de ces circulations implique l’exploitation d’un corpus large,

1. *EdIter et analyser les Diagrammes astronomiques historiques avec l’intelligence Artificielle*, URL : <https://anr.fr/Projet-ANR-22-CE38-0014> (visité le 10/08/2023).

représentatif des bornes chronologiques et géographiques du projet, qui s'étendent de l'Europe à l'Asie, du VIII^e au XVIII^e siècle. Le projet EIDA a pour objectif d'étudier la diversité des diagrammes produits, du point de vue de l'utilisation mais aussi du support et de la diffusion. Les diagrammes sont étudiés d'un point de vue épistémique, par la définition de différentes typologies de diagrammes, l'analyse de leurs utilisations dans divers contextes et l'étude des sujets mathématiques et astronomiques qui les implique ; ainsi que d'un point de vue documentaire, avec un intérêt pour leurs contextes de production, le rapport texte-diagramme dans les manuscrits, et la circulation des représentations à une échelle locale ou globale.

Le projet s'appuie sur des sources latines, byzantines, arabes, persanes, hébraïques, sanskrites et chinoises, qui partagent des éléments communs permettant ainsi de retracer les évolutions des sciences astronomiques, et d'étudier leur continuité, leur diversité, et leurs connections à travers l'histoire de l'astronomie.

Le choix de la vision artificielle

Profondément ancré dans les méthodes des humanités numériques, le projet EIDA a pour objectif le développement d'une approche reposant sur la vision artificielle, qui permettrait d'appliquer au corpus une série de traitements en prévision de leur analyse et de leur exploitation. Le développement d'outils basés sur la vision artificielle a pour but de limiter les étapes manuelles de fouille et d'annotation dans le corpus de manuscrits, en automatisant les étapes d'extraction des diagrammes dans les numérisations, et leur transformation en objets aisément manipulables pour leur analyse, comme pour l'édition. La projet EIDA repose ainsi, dans ses principes fondateurs, sur une approche interdisciplinaire mêlant histoire des sciences et vision artificielle, avec pour objectif l'analyse de sources historiques dans le domaine des sciences astronomiques et le développement d'outils pour l'étude des diagrammes.

Dans une perspective de science ouverte, le projet EIDA prévoit le développement d'une application Web dédiée à l'extraction, la visualisation, l'étude et l'édition de diagrammes ; une plateforme dédiée à la communauté de la recherche qui permettra une utilisation des données produites et des outils développés par EIDA via une interface web. Cette plateforme permettra à un public de chercheurs, d'étudiants ou d'amateurs d'exploiter les algorithmes développés dans le cadre du programme pour traiter leurs propres sources ; à l'image de la plateforme développée dans le cadre du projet DISHAS (*Digital Information System for the History of Astral Sciences*), dédié aux tables astronomiques.

Annotations et données ouvertes

Le projet EIDA ayant pour objectif de produire un modèle de vision par ordinateur performant pour la détection de diagrammes dans des numérisations de manuscrits, un

jeu de données d’entraînement – ou vérité de terrain – est produit à partir d’annotations réalisées par les chercheurs du programme. Ce jeu de données est composé d’un ensemble d’images et de leurs fichiers d’annotation où sont localisés manuellement les diagrammes, selon les résultats espérés de la détection automatique. Cette vérité de terrain se veut, pour des meilleurs résultats, la plus exhaustive possible quant au matériau source, et constitue ainsi un jeu de données diversifié en termes d’images et d’annotations, aussi bien du point de vue de la période que de la provenance géographique, ou simplement du style de représentation.

EIDA prévoit ainsi de mettre à disposition ce jeu de données, pour permettre son exploitation par d’autres projets qui souhaiteraient entraîner un modèle de vision artificielle pour la détection d’objets dans des images. Il est envisagé, pour le bon référencement de ce jeu de données, de les référencer dans un catalogue à l’image de l’initiative HTR-United² pour la reconnaissance automatique des écritures manuscrites. L’annotation étant une étape cruciale des projets en *machine learning*, l’ouverture de ces données permettra ainsi à d’autres projets de bénéficier du travail effectué dans le cadre d’EIDA.

1.1.2 Avant EiDA : le projet DISHAS

Étudier les tables astronomiques

Précédant le projet EIDA, DISHAS s’intéresse au développement des sciences astronomiques, à leur circulation, à leur transmission à travers les cultures et les époques, par le prisme des tables. De la même manière que les diagrammes sont un objet d’étude permettant de retracer des traditions scientifiques à travers les cultures eurasiennes, les tables sont un objet caractéristique des sciences astronomiques, dont le contenu numérique rend possible l’alignement et la comparaison entre différentes sources pour une étude de la circulation des idées entre les cultures et les pratiques scientifiques.

Le projet DISHAS emploie les méthodologies des humanités numériques et les applique au traitement des sources en histoire de l’astronomie. Dans cette optique, une application dédiée à l’édition et à l’analyse des tables astronomiques a été mise en ligne³ : cette application propose une contextualisation historique, chronologique et géographique des tables⁴, ainsi qu’une série d’outils plus spécifiques, pour leur étude par un public divers, plus ou moins spécialisé. Parmi ces outils dédiés au traitement des tables, DTI (*DISHAS Table Interface*) est destiné à la saisie de tables numériques et DIPS (*DISHAS Interactive*

2. HTR-United ne propose pas de cataloguer des jeux de données pour la *computer vision*, il est cependant envisagé de prendre contact avec les porteurs de l’initiative pour discuter de la possible intégration des données du projet EIDA. Alix Chagué et Thibault Clérice, *HTR-United*, URL : <https://htr-united.github.io/index.html> (visité le 10/08/2023)

3. *Home — DISHAS Project — Astronomical Table in Database*, URL : <https://dishas.obspm.fr/> (visité le 10/08/2023).

4. *Historical Navigation — DISHAS Project — Astronomical Table in Database*, URL : <https://dishas.obspm.fr/historical-navigation> (visité le 10/08/2023).

Parameter Squeezer) propose l’analyse mathématique de tables astronomiques anciennes ; mettant ainsi à disposition de la communauté de la recherche les résultats du projet, pour que les données comme les outils puissent être utilisés dans le cadre de recherches dans le domaine de l’histoire des sciences.

Approche par la vision artificielle

L’approche des données visuelles par l’intelligence artificielle est un élément clé du projet DISHAS, ayant donné lieu au développement de *tableTranscriber*⁵, un outil dédié à la détection par un algorithme de vision artificielle⁶ de la structure des tables, afin d’en transcrire le contenu manuscrit à l’aide d’un algorithme de HTR. L’objectif de *tableTranscriber* est ainsi d’automatiser la chaîne de traitement des numérisations de tables astronomiques manuscrites, afin d’obtenir des données au format XML, CSV ou HTML, aisément manipulables pour une analyse des sources.

Cette volonté collaborative dans le développement d’outils numériques est centrale au projet EIDA qui, comme son prédécesseur DISHAS, vise à produire une recherche communautaire, aux acteurs scientifiques divers, à l’intersection des humanités numériques et de l’histoire des sciences.

1.1.3 Acteurs du projet

SYRTE-PSL-Observatoire de Paris, CNRS

EIDA est un projet interdisciplinaire mené en collaboration avec de nombreux acteurs et institutions, pour en faire un projet réellement collaboratif dans la réalisation de ses objectifs. Au sein de l’Observatoire de Paris, l’équipe est composée d’historiens et d’ingénieurs affiliés au SYRTE (Systèmes de Référence Temps-Espace), ayant pour la plupart collaboré au projet DISHAS, et possédant donc une expérience de la recherche en histoire des sciences, et en humanités numériques. L’équipe compte également des chercheurs indépendants et collaborateurs scientifiques externes, qui assurent la diversité du corpus en contribuant à EIDA par leur expertise dans des sources issues d’aires géographiques et chronologiques qui s’ajoutent à celles représentées dans l’équipe d’histoire des sciences de l’Observatoire de Paris.

Du point de vue des institutions, le groupe de recherche en vision artificielle IMAGINE (Laboratoire d’Informatique Gaspard Monge) basé à l’École des Ponts ParisTech, co-ordonne le projet EIDA, et assure notamment les recherches en vision artificielle et apprentissage machine nécessaires à la réalisation des objectifs du projet. Le projet VHS

5. tristan-dot, *tableTranscriber : An Automatic Pipeline for Astronomical Tables Transcription*, oct. 2022, URL : <https://github.com/tristan-dot/tableTranscriber> (visité le 10/08/2023).

6. Basé sur monniert, *docExtractor*, juill. 2023, URL : <https://github.com/monniert/docExtractor> (visité le 10/08/2023).

(Vision artificielle et analyse Historique de la circulation de l'illustration Scientifique), coordonné par l'Institut des sciences du calcul et des données, est également partenaire d'EIDA pour le développement des algorithmes de détection et de la plateforme dédiée aux chercheurs.

Algorithmes de vision par ordinateur : le groupe de recherche IMAGINE

L'équipe IMAGINE– avec laquelle l'équipe d'histoire des sciences avait déjà collaboré pour le développement de tableTranscriber dans le projet DISHAS– apporte au projet EIDA son expertise dans le domaine de l'apprentissage profond et de la vision artificielle appliqués aux humanités numériques. Les recherches menées entre 2018 et 2022 dans le cadre du projet EnHerit (*Enhancing Heritage Image Databases*)⁷, dédié à l'application d'algorithmes de vision à l'histoire de l'art pour la reconnaissance de motifs dans les œuvres d'art, sont le socle des développements menés pour les projets EIDA et VHS.

Dans le cadre de leur participation à EIDA, l'objectif des chercheurs d'IMAGINE est le développement de nouvelles approches⁸ pour permettre la décomposition et la vectorisation de dessins techniques. Ces nouvelles approches par vision par ordinateur devraient permettre l'analyse et l'édition de diagrammes astronomiques sans intervention humaine, avec une méthode plus flexible dans son apprentissage, qui allègerait ainsi les étapes d'annotation nécessaires à l'apprentissage profond.

Ces recherches en apprentissage faiblement supervisé sont également menées dans le cadre du projet VHS, auquel l'équipe IMAGINE contribue également, avec un accent mis sur la détection de similarité dans les images et dans le texte, qui devraient permettre une navigation facilitée des corpus étudiés, et qui seront également exploitées dans EIDA.

Le projet ANR VHS

Le projet VHS réunit des chercheurs en histoire des sciences et en vision artificielle pour l'étude de la circulation des savoirs scientifiques au Moyen-Âge et à la période moderne. Coordonné par Alexandre Guilbaud, VHS a pour objectif de développer des méthodes d'analyse de corpus illustrés par apprentissage profond, afin d'étudier la circulation, l'évolution et la réutilisation des images scientifiques dans le cadre de la transmission des savoirs à travers les époques et les zones géographiques, et d'analyser le rapport des images au contenu textuel des ouvrages dans lesquels elles figurent. Les méthodes développées par le projet ont pour objectif de limiter la nécessité des annotations pour l'obtention de résultats dans la détection de similarité, qui permettraient ainsi de faciliter la navigation

7. *Enhancing Heritage Image Databases*, URL : <https://anr.fr/Project-ANR-17-CE23-0008> (visité le 10/08/2023).

8. Basées sur les progrès récents de l'analyse par synthèse. Tom Monnier, Elliot Vincent, Jean Ponce et Mathieu Aubry, *Unsupervised Layered Image Decomposition into Object Prototypes*, août 2021, DOI : 10.48550/arXiv.2104.14575, arXiv : 2104.14575 [cs]

de corpus scientifiques par des regroupements et rapprochements basés sur les images et sur le texte.

Ces recherches s’accompagnent du développement d’une application Web, qui mettra à disposition de la communauté scientifique les outils et données produites dans le cadre du projet VHS, afin que ceux-ci puissent être exploités par d’autres équipes travaillant dans le domaine des études visuelles, ou souhaitant apporter une analyse sur des corpus illustrés par le prisme de la circulation des motifs et des idées.

Les membres de l’équipe IMAGINE sont sollicités lors des prises de décision relatives aux travaux menées par les chercheurs⁹ et participent aux discussions relatives au développement de la plateforme. De plus, pour un développement plus fluide des applications VHS et EIDA, l’ingénieur chargé de ce développement pour le projet VHS mène régulièrement ses travaux à l’Observatoire, pour faciliter les échanges entre les deux équipes. Ces collaborations permettent une mutualisation des recherches et expertises des différents projets, ainsi que le développement commun d’outils réutilisables qui bénéficient des regards variés et complémentaires des différents acteurs.

1.2 Sources primaires

1.2.1 L’astronomie ptoléméenne : naissance et diffusion

L’Almageste et le modèle ptoléméen

L’astronomie et les disciplines qui y sont liées sont, dès l’Antiquité, cultivées dans un grand nombre de cultures où se développent des pratiques variées, appuyées sur l’observation des objets célestes et le développement de systèmes mathématiques pour en prédire le comportement. Jusqu’à l’arrivée des théories de Nicolas Copernic au XV^e siècle, les travaux de Ptolémée¹⁰ influencent, à travers l’Eurasie, les productions des astronomes. L’œuvre de Ptolémée devient en effet dès le II^e siècle une référence en matière d’astronomie : développées sur les travaux de ses prédécesseurs grecs, les théories de Ptolémée approfondissent les productions de son temps dont il fait la synthèse dans ses travaux, et qu’il enrichit de ses propres observations. Si le modèle géocentrique est déjà établi avant l’achèvement de *L’Almageste*, les travaux de Ptolémée perfectionnent la théorie des épicycles¹¹, et parviennent à l’affiner avec une précision suffisante pour la prédiction des

9. On considère l’annotation des diagrammes dans les manuscrits comme un travail de recherche.

10. Claude Ptolémée (v. 100-v. 170) est un astronome, mathématicien et géographe actif à Alexandrie au II^e siècle de notre ère. *L’Almageste*, complété vers 150, comprend un quart de siècle d’observations des mouvements des objets célestes, expliqués par des systèmes mathématiques qu’il développe dans son œuvre. Le système ptoléméen désigne le modèle géocentrique de l’univers qu’il développe dans ses travaux. Alexander Raymond Jones, « Ptolemy », dans *Encyclopedia Britannica*, URL : <https://www.britannica.com/biography/Ptolemy> (visité le 03/08/2023).

11. Introduite par les astronomes de la Grèce antique, la théorie des épicycles permet, dans un modèle géocentrique, d’expliquer les changements de vitesse et de direction dans le mouvement observé

positions des planètes, notamment par l'introduction du point équiant¹².

L'*Almageste* est constitué d'observations et descriptions des procédures mathématiques appliquées par Ptolémée pour établir les paramètres de son modèle géométrique¹³. À ses explications textuelles s'ajoutent des tables de valeurs numériques calculées par Ptolémée qui permettent, en suivant ses explications, de calculer la position des planètes, en tant qu'application de ses théories. Dans les siècles qui suivent le développement du modèle ptoléméen, peu d'innovations ont lieu dans les sciences astronomiques de tradition hellénique, et les travaux produits prennent essentiellement la forme de commentaires des théories de Ptolémée, sans remise en cause de son modèle, qui reste la norme pendant plusieurs siècles et est diffusé à travers l'Eurasie par le biais de traductions.

Diffusion du modèle ptoléméen

Avant les Grecs, les Babyloniens pratiquent, dès le I^{er} millénaire av. J.-C., une astronomie basée sur des calculs arithmétiques permettant de prédire la position des planètes. L'astronomie indienne hérite de ces théories des sciences astronomiques babyloniennes qu'elle mêle avec des méthodes locales, qui s'enrichissent plus tard des travaux de Ptolémée et de son prédécesseur Hipparque, dont les idées voyagent vers l'Est¹⁴ par le biais de la Perse.

À partir du VIII^e siècle, dans le monde islamique, se développe une pratique de l'astronomie à l'intersection des théories grecques, babyloniennes, perses et indiennes. Suivant le modèle des tables de Ptolémée, les astronomes arabes développent au IX^e siècle des ouvrages de tables, appelés *zīj*, dédiés au calcul des positions du Soleil, de la Lune et des planètes mêlant ces diverses traditions. La traduction en arabe – pendant le califat abbasside¹⁵ – des écrits de Ptolémée permet aux astronomes du monde islamique d'enrichir leurs pratiques en l'inscrivant dans cette tradition, tout en améliorant certains paramètres calculés dans le cadre de son modèle pour en préciser les prédictions¹⁶. Si des critiques des

des planètes, du Soleil et de la Lune. Selon cette théorie, les objets célestes se déplacent à vitesse uniforme sur un cercle appelé épicycle, dont le centre est lui-même en rotation sur un cercle centré sur la Terre appelé déférent. Jean-Jacques Rousseau, *Epicycles de Ptolémée*, URL : <http://ressources.univ-lemans.fr/AccesLibre/UM/Pedago/physique/02/divers/ptolemee.html> (visité le 05/08/2023)

12. En effet, la théorie des épicycles telle qu'elle existe avant l'intervention de Ptolémée ne permet pas de justifier précisément des mouvements observés des planètes. Ptolémée introduit ainsi la notion de point équiant, point excentré par rapport au centre de la Terre, à partir duquel la vitesse de rotation des corps céleste est constante. Ce modèle géométrique permet de calculer avec précision le mouvement longitudinal des planètes. James Evans, « History of Astronomy », dans *Encyclopedia Britannica*, URL : <https://www.britannica.com/science/astronomy/Ancient-Greece> (visité le 03/08/2023)

13. *Ibid.*

14. *Ibid.*

15. La dynastie sunnite des Abbassides gouverne le monde musulman de 750 à 1258. La capitale du califat, Bagdad, est le siège d'entreprises de traduction vers l'arabe d'écrits scientifiques, notamment depuis le grec.

16. L'écart temporel entre les calculs de Ptolémée et ceux des astronomes arabes du IX^e siècle permettent également de mettre en évidence certains déplacements observables seulement sur un temps plus long, tels que la diminution de l'obliquité de l'écliptique.

travaux de Ptolémée émergent, notamment au XI^e siècle dans les écrits d'Ibn al-Haytham, son modèle reste prédominant jusqu'aux travaux de Copernic¹⁷.

Dans le monde latin, les théories grecques se sont peu transmises, et l'enseignement de l'astronomie s'appuie essentiellement sur les écrits de Plin l'Ancien. Au XII^e et XIII^e siècles, les textes grecs sont rendus disponibles par des initiatives de traduction : Gérard de Crémone, notamment, traduit *L'Almageste*¹⁸ de l'arabe vers le latin, participant activement à la redécouverte du modèle ptoléméen par les scientifiques du monde latin. La transmission des écrits et théories astronomiques ne se fait donc pas directement des Grecs au Latin, mais a pour intermédiaires les traductions effectuées aux siècles précédents dans le monde arabo-musulman. En parallèle, le développement des universités réintègre l'astronomie à l'enseignement des arts libéraux : dans ce contexte d'émulation, de nouveaux ouvrages sont publiés, et notamment des tables astronomiques, toujours basés sur le modèle ptoléméen.

Les sources chinoises témoignent d'une pratique de l'astronomie aussi ancienne que le II^e millénaire av. J.-C. sous la forme de prédiction des éclipses du Soleil et de la Lune. Cette pratique est profondément liée à la culture impériale, et les éclipses – puis plus tardivement, les planètes – sont un outil d'analyse du règne d'un empereur. Plus proche des procédures babyloniennes que du modèle géométrique grec, l'astronomie chinoise s'appuie avant tout sur l'arithmétique pour ses prédictions, et s'intéresse principalement aux événements ponctuels – tels que les comètes ou les éclipses – plutôt qu'aux mouvements des corps célestes¹⁹.

Jusqu'à l'émergence du modèle héliocentrique, et la mise au centre de la pratique des théories de Copernic, le modèle ptoléméen représente, dans de nombreux contextes culturels, le socle des méthodes des sciences astronomiques. Qu'il soit amélioré, contesté, ou enrichi de pratiques locales, il reste un standard de la conception de l'astronomie en Eurasie, et permet ainsi de retracer une tradition des pratiques à travers les siècles.

1.2.2 Les diagrammes

Une culture visuelle des sciences astronomiques

Dans le contexte eurasiatique, les supports détaillant les pratiques des astronomes circulent entre les siècles et les cultures, sont enrichis ou adaptés aux pratiques autochtones de l'astronomie, en réponse aux besoins spécifiques de chaque contexte culturel. Les manuscrits et imprimés, supports de ces pratiques, sont les témoins de ces échanges intellectuels et permettent d'établir une histoire des idées et des méthodes héritées du modèle ptoléméen (fig. 1.1). Ces œuvres comprennent, en support des pratiques, des textes, des

17. *Ibid.*

18. Ainsi que d'autres versions arabes de textes grecs, tels que *Du ciel* d'Aristote, ou les *Éléments* d'Euclide.

19. *Ibid.*

tables et des diagrammes, tous porteurs des méthodes et théories des sciences astronomiques : le projet DISHAS ayant mené une étude sur les tables astronomiques, il semble naturel qu'EIDA, dans la continuité de celui-ci, ait pour vocation de s'intéresser spécifiquement aux diagrammes. Les astronomes, dans leur pratique, n'hésitent pas à employer des modes d'expression visuels, au-delà du texte, qu'il convient d'étudier en parallèle de celui-ci pour en comprendre les interactions. Ainsi, il est nécessaire de développer des outils permettant d'appréhender les formes variées que peuvent prendre les sources en histoire de l'astronomie ; à l'image des récentes recherches en histoire des sciences, qui s'appliquent notamment à une étude des sources visuelles, non-discursives, de la pratique scientifique, et en considérant les illustrations comme des objets d'étude à part entière, au-delà d'un simple accompagnement du contenu textuel²⁰.

En tant que vecteurs d'une culture visuelle de l'astronomie, les diagrammes sont, pour les astronomes, le support d'une pratique scientifique, et sont ainsi révélateurs de leurs méthodes, de leur contexte d'exercice et de leur conception de ces disciplines. Le projet vise à proposer une analyse de ces diagrammes qui souligne la variété de leurs fonctions et des traditions auxquelles ils appartiennent, tout en étudiant leurs modes de circulation à travers l'histoire de l'astronomie. Dans la diversité de leurs sphères de création, ces diagrammes reçoivent « une légitimité en tant qu'instruments pédagogiques et vecteurs de la pensée²¹ », et occupent ainsi dans le contexte d'une culture visuelle globale une place particulière.




FIGURE 1.1 – Modèles lunaires de tradition arabe, byzantine et latine

Bornes géographiques et chronologiques

Ayant la volonté de produire une étude des circulations et évolutions des diagrammes astronomiques, EIDA s'attache à l'étude de sources provenant de sphères géographiques

20. Boris Jardine et Nicholas Jardine, « Critical Editing of Early-Modern Astronomical Diagrams », *Journal for the History of Astronomy*, 41–3 (août 2010), p. 393-414, DOI : 10.1177/002182861004100307, p. 394

21. « [...] legitimacy as instruments of pedagogy and as vehicle of thought ». Jeffrey F. Hamburger, David J. Roxburgh et Linda Safran (éd.), *The Diagram as Paradigm : Cross-Cultural Approaches*, Cambridge, MA, 2022 (Dumbarton Oaks Byzantine Symposia and Colloquia), p. 1.

et temporelles larges : les pratiques eurasiatiques des sciences astronomiques partagent des éléments communs qui justifient une étude au cadre vaste, pour proposer une analyse transculturelle des continuités et divergences dans l’histoire de l’astronomie comme dans la culture visuelle. Pour répondre à cette volonté, le projet EIDA s’appuie sur cinq corpus aux provenances temporelles et géographiques diverses, provenant de traditions diverses également, dans une volonté de représentativité.

Les manuscrits astronomiques arabo-persans, produits du VIII^e au XVIII^e siècle, représentent à eux seuls un corpus d’une grande diversité, aux traditions diverses aussi bien du point de vue des pratiques que de la provenance géographique. Les travaux produits dans ces contextes circulent à travers l’Eurasie du Moyen-Âge au début de la période moderne, et influencent de nombreuses pratiques. Les manuscrits d’astronomie latin médiévaux sont produits majoritairement entre le XIII^e et le XVI^e siècle dans un contexte universitaire, et sont influencés par les traductions faites de l’arabe au latin de textes de tradition arabe ou persane. Les manuscrits byzantins, produits entre les IX^e et XV^e siècles sont à l’intersection des traditions helléniques, latines et arabo-persanes, et influencent considérablement les manuscrits astronomiques latins du XV^e et du XVI^e siècle. Les manuscrits sanskrits, dont la diversité reflète les nombreuses traditions établies sur près de deux millénaires, témoignent à partir du XI^e siècle d’influences helléniques puis arabo-persanes. Les sources chinoises, dont le support n’est pas nécessairement le manuscrit, prennent souvent la forme d’imprimés par blocs xylographiques dont les matrices sont réemployées à travers plusieurs témoins. Ces documents témoignent des influences arabo-persanes puis latines des pratiques astronomiques chinoises à partir de la dynastie Ming²². Les sources étudiées dans le cadre d’EIDA proviennent essentiellement des dynasties Ming et Qing²³.

Les bornes de ces cinq corpus représentent les bornes chronologiques et géographiques du projet. S’étendant du VIII^e au XVIII^e siècle, les périodes et aides étudiées se veulent représentatives du contexte afro-eurasien de la circulation des idées et des images. Ces corpus représentent, dans chaque cas, plusieurs milliers de manuscrits. Plusieurs centaines de manuscrits sont numérisés pour chaque tradition représentée dans le projet, permettant ainsi la représentativité espérée dans le cadre du projet EIDA. Ces numérisations, mises à disposition par les institutions patrimoniales qui conservent ces témoins, représentent les sources primaires du projet, sur lesquelles seront appliquées les traitements en prévision de l’analyse par les chercheurs.

EIDA est un projet aux bornes chronologiques, géographiques et thématiques vastes, pour permettre une étude sur un temps long et dans un contexte global de la circulation des diagrammes astronomiques et des théories scientifiques qui les accompagnent. Dans cette démarche, proposer une étude quantitative, traitant un grand nombre de sources, per-

22. La dynastie Ming règne sur la Chine de 1368 à 1644.

23. La dynastie Qing, dernière dynastie impériale chinoise, règne de 1644 à 1912.

met de mettre en avant des motifs, connexions et évolutions en accord avec la diffusion afro-eurasienne des idées développées par Ptolémée. Les bornes définies dans cette partie permettent de délimiter un corpus d'images – numérisations d'ouvrages manuscrits ou imprimés – qui en tant d'objets numériques présentent également leurs propres problématiques, sur lesquelles revient la partie suivante.

Chapitre 2

Images et interopérabilité

Les sources étudiées dans ce mémoire sont des sources iconographiques : cette partie vise à revenir sur les formats, ressources et méthodes pour le traitement des images en ligne, de la production de la ressource à sa publication. Les images digitales présentent des enjeux spécifiques, du point de vue de la technique, du droit et de la disponibilité. La mise en ligne et la diffusion d'une image fait suite à une longue chaîne de traitement qui a pour point de départ un objet matériel, et soulève des questionnements divers. Les spécifications IIF (*International Image Interoperability Framework*) tente de répondre à un certain nombre de problématiques liées à la présence en ligne de ressources iconographiques, et cette partie vise donc à présenter les solutions, possibilités et limites offertes par ce standard.

2.1 L'image comme source

2.1.1 Construire un corpus d'images : enjeux et méthodes

La numérisation, enjeu patrimonial

L'application à un corpus de sources historiques de méthodes numériques repose sur une première étape cruciale dans le traitement de ces sources : la numérisation des collections patrimoniales. De la bibliothèque au musée, la numérisation du patrimoine culturel est un enjeu crucial depuis le début des années 1990¹. Pensée initialement comme un outil de préservation, de valorisation et d'accessibilité aux collections², la mise à disposition des collections au format numérique ouvre également la voie à de nouvelles méthodologies

1. Corinne Baujard, « Numérisation du patrimoine culturel et stratégie managériale des musées », *Management des technologies organisationnelles*-7 (févr. 2017), p. 69-78, URL : <https://www.cairn.info/revue-management-des-technologies-organisationnelles-2017-2-page-69.htm> (visité le 06/08/2023).

2. Michel Richard, « Le programme de numérisation de la Bibliothèque de France », *Bulletin des bibliothèques de France*-3 (1993), p. 53-63, URL : <https://bbf.enssib.fr/consulter/bbf-1993-03-0053-007> (visité le 06/08/2023).

de la recherche, notamment dans le champs disciplinaire des humanités numériques : dans le cadre d'un projet tel qu'EIDA, qui prévoit des traitements automatiques des sources par des algorithmes de vision par ordinateur, la disponibilité des sources numérisées est un principe fondateur de la démarche de recherche.

La numérisation des données culturelles fait désormais partie des pratiques courantes des institutions culturelles, et plus particulièrement des bibliothèques, représentant une part intégrante du travail de conservation et de diffusion du patrimoine³. Dès le milieu 1990, des initiatives telles que Gallica⁴, bibliothèque numérique de la BnF (Bibliothèque nationale de France), voient le jour, et mettent à disposition du publique, au format numérique, les collections de la bibliothèque. Dans les années qui suivent, des initiatives telles qu'Europeana⁵, permettent le déploiement de projets de plus large envergure⁶, portant toujours cette responsabilité de préservation, diffusion et valorisation des collections dans un contexte international. La notion de patrimoine culturel numérique prend tout son sens, et Internet devient un espace permettant à des utilisateurs aux profils variés d'exploiter ces ressources numériques, et d'accéder à un patrimoine vaste, au-delà des limites physiques de la consultation des documents. Cependant, malgré les initiatives de soutien à la numérisation portées par les collectivités, ou même par l'État⁷, il est nécessaire de souligner les disparités, aussi bien sur le plan national qu'international, de ces entreprises de numérisation, souvent coûteuses : ainsi, il n'existe pas de réelle égalité entre les institutions dans la numérisation et la mise en ligne des collections, un biais qu'il est nécessaire de prendre en compte, et particulièrement dans des projets de recherche appuyés sur des sources aux bornes géographiques internationales.

Dans le cas des corpus étudiés par le projet EIDA, on compte, pour des sources qui représentent plusieurs centaines de milliers de documents, une somme de plusieurs centaines de documents numérisés, mis à disposition par les institutions patrimoniales européennes, chinoises et indiennes : nous constatons ainsi que les documents numérisés ne représentent qu'un fragment de la réalité des sources existantes, cependant, ces centaines de documents numérisés sont à la fois suffisantes et suffisamment représentatives pour le bon déroulé du projet.

Les collections patrimoniales des musées présentent un tout autre enjeu en termes de mise en ligne : les œuvres conservées, allant bien au-delà du format livre, ont une diversité qui redéfinit entièrement la notion de numérisation⁸. Tout comme les bibliothèques, les institutions muséales font face, avec le développement des pratiques numériques, à une

3. Thierry Claerr et Isabelle Westeel, « Mode d'emploi », dans *Numériser et mettre en ligne*, Villeurbanne, 2017 (La Boîte à outils), p. 7-18, DOI : 10.4000/books.pressesenssib.419.

4. *Gallica*, URL : <https://gallica.bnf.fr/> (visité le 10/08/2023).

5. *Europeana*, URL : <https://www.europeana.eu/fr> (visité le 10/08/2023).

6. Id., « Mode d'emploi »...

7. *Ibid.*

8. Par numérisation, dans le contexte muséal, nous entendons essentiellement la prise de photographies de haute qualité des œuvres d'arts.

transformation des pratiques de conservation pour inclure ces méthodes. Outre les aspects documentaires de la numérisation, le Web est un lieu d'exposition à part entière, et la numérisation des œuvres présentent ainsi un intérêt stratégique en termes de valorisation et de visibilité⁹. Dans le monde muséal, néanmoins, l'accès libre aux images n'est pas aussi systématique qu'en bibliothèque¹⁰ : il existe bel et bien des projets de numérisation de grande envergure, tels que Google Arts & Culture¹¹, publié en 2011. La vocation de ce type de projets, cependant, semble plutôt être la création d'espaces d'exposition dématérialisés permettant de mettre en valeur les œuvres pour des spectateurs, plutôt que la véritable mise à disposition de ces images pour un usage par des utilisateurs. Nous soulignons, notamment, dans le cas de Google Arts & Culture, l'impossibilité de copier les images avec un clic droit, et l'absence de bouton pour le téléchargement des numérisations sur un certain nombre de pages : les numérisations sont faites pour être vues, et non utilisées¹².

Une étude menée entre 2019 et 2020 par le Musée National de Tokyo souligne, en parallèle, les disparités dans la qualité des numérisations, qui ne permet ainsi pas de considérer qu'un objet numérisé ou photographié l'est nécessairement dans une qualité exploitable¹³, notamment parce que les besoins en termes de qualité ne sont pas les mêmes pour des œuvres en 2D et des œuvres en 3D, qui souffrent particulièrement de la mauvaise qualité des numérisations. Ainsi, en prenant en compte ces critères, il est nécessaire de soulever la question de la réelle exploitabilité des images mises en ligne, et particulièrement dans le cadre de projets en vision artificielle qui reposent, dans leurs fondations, sur la disponibilité et la qualité des images du corpus choisi. Des initiatives récentes tentent cependant de pallier à ces lacunes des institutions patrimoniales quant à la mise à disposition des images, comme la création en 2015 d'une API (*Application Programming Interface*) donnant accès aux reproductions de la base photographie de la Rmn-Grand Palais¹⁴, mais la norme, pour ces images d'œuvres d'art, reste loin de l'*open access*¹⁵.

9. C. Baujard, « Numérisation du patrimoine culturel et stratégie managériale des musées »...

10. Pour comparaison, Gallica représente aujourd'hui près de 10 millions de documents, et la base de la Rmn-Grand Palais (Réunion des musées nationaux-Grand Palais) compte 600 000 œuvres numérisées.

11. *Google Arts & Culture*, URL : <https://artsandculture.google.com/> (visité le 10/08/2023).

12. Certaines œuvres du projet sont disponibles sur Wikimedia, mais ces images en accès libre ne représentent qu'un fragment des œuvres numérisées dans le cadre du projet. De plus, les musées français sont très peu représentés dans cette sélection. *Category :Google Art Project Works by Collection - Wikimedia Commons*, URL : https://commons.wikimedia.org/wiki/Category:Google_Art_Project_works_by_collection (visité le 10/08/2023)

13. Akira Sakai, *Digitizing Disparity in the Museum. The Object-Based Research in the Tokyo National Museum*, août 2021, URL : <https://universityheritage.eu/en/digitizing-disparity-in-the-museum-the-object-based-research-in-the-tokyo-national-museum/> (visité le 06/08/2023).

14. *API de La Rmn-Grand Palais*, URL : <https://api.art.rmngp.fr/> (visité le 10/08/2023).

15. Isabelle Manca, « Les nouveaux défis des agences photographiques des musées », *Le Journal Des Arts* (, juin 2018), URL : <https://www.lejournaldesarts.fr/patrimoine/les-nouveaux-defis-des-agences-photographiques-des-musees-138076> (visité le 06/08/2023).

Droit d’auteur et coût des images

La numérisation et la mise en ligne de documents patrimoniaux implique également de prendre en compte la question des droits d’auteur, qui régit souvent les possibilités des institutions en termes de libre accès, et impacte par conséquent les projets, aussi bien du point de vue des exploitations possibles que de la publication de leurs résultats¹⁶.

Une œuvres originale est protégée au titre du droit d’auteur : ce droit comprend le droit moral, perpétuel et inaliénable, qui donne droit au respect de l’œuvre et du nom de son auteur, ainsi que le droit patrimonial, qui donne à l’auteur et ses ayants droit le droit d’autoriser ou non la reproduction et la diffusion de l’œuvre¹⁷. Les droits patrimoniaux s’éteignent soixante-dix ans après la mort de l’auteur, et l’œuvre entre alors dans le domaine public¹⁸. Il n’existe pas d’exception au droit d’auteur pour une numérisation mise en ligne sur Internet¹⁹. Ces droits, qui s’appliquent à l’œuvre originale, ne sont pas nécessairement ceux qui nous intéressent dans le cadre d’un projet de recherche en histoire, dont les œuvres du corpus ont souvent rejoint le domaine public. La photographie d’une œuvre, cependant, peut faire l’objet du droit d’auteur, si celle-ci n’est pas considérée comme une reproduction servile.

Outre le droit d’auteur et les droits du photographe, les institutions peuvent exiger une redevance de réutilisation ou de prestation d’un service pour l’utilisation de leurs images, qui sert à couvrir, par exemple, les frais engagés pour la production du cliché, le traitement de la demande, ou la recherche iconographique²⁰. Beaucoup d’institution, telles que la BnF et l’INHA (Institut national d’histoire de l’art)²¹, proposent des tarifications particulières pour des projets académiques, scientifiques ou non commerciaux, et n’appliquent un coût qu’en cas de demande de numérisation d’œuvres qui ne sont pas déjà numérisées. Les projets de recherche peuvent ainsi faire le choix de construire leurs corpus en prenant en compte les documents déjà disponibles, et mis en ligne sous licence libre.

16. Olivier Jacquot, *Décrire, transcrire et diffuser un corpus documentaire hétérogène : méthodes, formats, outils*, Billet, nov. 2017, URL : <https://bnf.hypotheses.org/2214> (visité le 06/08/2023).

17. Sophie Sepetjan, « Respecter le droit de la propriété littéraire et artistique », dans *Numériser et mettre en ligne*, dir. Thierry Claerr et Isabelle Westeel, Villeurbanne, 2017 (La Boîte à outils), p. 46-64, DOI : 10.4000/books.pressesenssib.426.

18. Il existe des cas particuliers, notamment pour les œuvres collectives ou les journaux, ainsi que pour les publications posthumes. Institut national d’histoire de l’art, *Guide Pratique Pour La Recherche et La Réutilisation Des Images d’œuvres d’art*, URL : https://www.inha.fr/_resources/PDF/2021/2021_LIVRET_GUIDE-PRATIQUE_web_15062021.pdf.

19. S. Sepetjan, « Respecter le droit de la propriété littéraire et artistique »...

20. Institut national d’histoire de l’art, *Guide Pratique Pour La Recherche et La Réutilisation Des Images d’œuvres d’art*...

21. Martine Denoyelle, *A propos du coût des images d’œuvres patrimoniales*, Billet, juin 2021, URL : <https://numrha.hypotheses.org/2142> (visité le 06/08/2023).

2.1.2 Images et données ouvertes

Licences Creative Commons

Pour favoriser la libre circulation des images sur le Web, des licences ont été créées pour encadrer la réutilisation des numérisations. Dès 2001, les licences Creative Commons²² sont créées avec la vocation de favoriser la diffusion et le partage des images dans un contexte numérique, en assouplissant notamment les droits de propriété intellectuelle pour s'adapter à ce nouveau cadre. Ces licences se basent sur un système de quatre options qu'il est possible de combiner pour créer six licences différentes. Ces options sont attribution (BY), non commercial (NC), sans modification (ND) et partage à l'identique (SD)²³.

À partir de 2011, l'État français crée ses propres licences ouvertes, comme la licence unique Etalab, qui vise à « permettre et encourager la réutilisation des données publiques²⁴ ». Une deuxième version, publiée en 2017, se veut compatible avec la licence CC BY, c'est-à-dire une licence ouverte avec attribution de l'œuvre à son auteur.

Les données ouvertes sont un enjeu central des politiques culturelles : dans un contexte patrimonial, ces licences libres, conçues pour adapter les droits de propriété intellectuelle au contexte particulier du numérique, permettent ainsi la circulation, la diffusion et le partage de l'information. Il n'existe pas encore de cadre juridique international régissant l'utilisation des images produites par numérisation de collections patrimoniales, ainsi, les institutions sont soumises au droit spécifique du pays qui les abrite. En l'absence d'un encadrement global des pratiques, les utilisateurs – et notamment la communauté de la recherche – font face aux exceptions propres à chaque contexte national, qui représentent encore un obstacle. Une réflexion autour de ce cadre juridique international permettrait, en parallèle, d'harmoniser à une échelle globale les formats des données ouvertes²⁵, pour en faciliter la réutilisation par les institutions et par les projets.

Enjeux techniques : images et métadonnées

Le document numérique obtenu à la suite d'un processus de numérisation est, en réalité, constitué de plusieurs fichiers répondant à des besoins différents pour la mise en ligne. Chacun de ces éléments représentent leurs propres enjeux techniques, dont la gestion impacte la qualité et l'exploitabilité des images mises en ligne à la suite d'entreprises de numérisation.

22. Ces licences ne sont plus reconnues par l'État français depuis 2016. Id., *En savoir plus sur la licence Etalab et les autres licences*, Billet, juin 2021, URL : <https://numrha.hypotheses.org/2134> (visité le 06/08/2023).

23. Institut national d'histoire de l'art, *Guide Pratique Pour La Recherche et La Réutilisation Des Images d'œuvres d'art...*

24. M. Denoyelle, *En savoir plus sur la licence Etalab et les autres licences...*

25. Yaniv Benhamou, « Droit d'auteur et musées numériques », *Magazine de l'OMPI-3* (juin 2016), URL : https://www.wipo.int/wipo_magazine/fr/2016/03/article_0005.html (visité le 06/08/2023).

Les fichiers image issus d'un processus de numérisation peuvent avoir plusieurs formats²⁶ aux propriétés similaires mais différentes. En premier lieu, il est de bonne pratique de privilégier un format ouvert²⁷, par opposition à un format propriétaire qui nécessite un logiciel spécifique pour être lu. Le choix d'un format ouvert permet d'assurer l'accessibilité des données produites. Les formats .tiff et .jpeg sont favorisés dans le contexte de numérisation des collections patrimoniales, parce qu'ils permettent notamment la compression des fichiers²⁸ tout en maintenant la haute qualité des images²⁹. Les choix effectués par les institutions impactent la qualité des numérisations produites qui, sur un plus long terme, impacte aussi bien la préservation des données, l'expérience des utilisateurs qui consultent les images, et l'exploitabilité des fichiers par des projets. La question de la qualité des images est cruciale dans le cadre d'un projet de recherche en vision artificielle, puisque celle-ci a la possibilité d'impacter les performances de l'algorithme utilisé, et d'affecter négativement les interprétations du modèle³⁰.

Les fichiers images sont systématiquement accompagnés de métadonnées de diverses catégories, qui visent à décrire et identifier le document. Bien qu'il n'existe pas de standard international obligatoire concernant les métadonnées de numérisation, la standardisation des fichiers de métadonnées selon certains standards spécifiques permet de fluidifier la communication et les échanges entre institutions, dans une perspective interopérable qui permettrait de sortir des silos de données. Les métadonnées sont de plusieurs types : descriptives³¹, administratives³², structurelles³³; elles ont pour vocation de gérer tous ces aspects du document numérique. Ces métadonnées sont cruciales pour l'identification et la classification des documents numérisés, mais aussi pour permettre la recherche et la navigation à travers les collections. Malgré leur importance, les différentes institutions ont une gestion profondément hétérogène de leurs métadonnées, sans uniformisation nationale ou internationale, et avec une disparité profonde entre les différents types d'institutions patrimoniales.

Pour pallier à cette disparité dans la gestion des métadonnées et au manque de standards pour le partage des images en ligne, des initiatives internationales ont vu le

26. Un format décrit la manière dont les informations sont organisées dans un fichier.

27. Camille Besse, *Numérisation de Masse : Vers La Création d'un Nouvel Acteur de l'information. Le Projet Time Machine*, Paris, 2019.

28. La compression sans perte s'effectue par identification et suppression des redondances, c'est-à-dire des pixels identiques. Cette méthode n'est pas irréversible, il est possible de décompresser le fichier.

29. *Digital Images*, 2020, URL : <https://livecode.byu.edu/images/DigitalImages.php> (visité le 07/08/2023).

30. Austin C. Bergstrom et David W. Messinger, « Image Quality and Computer Vision Performance : Assessing the Effects of Image Distortions and Modeling Performance Relationships Using the General Image Quality Equation », *Journal of Electronic Imaging*, 32 (mars 2023), p. 023018, DOI : 10.1117/1.JEI.32.2.023018.

31. Pour identifier le contenu du document numérique, le rattacher au document original.

32. Pour gérer les droits d'accès, préserver les informations techniques, suivre les modifications du fichier et garantir son intégrité.

33. Pour rattacher les fichiers entre eux et reconstituer la structure du document.

jour, visant à mettre fin à cette gestion en silo des données des institutions patrimoniales pour faciliter les échanges et la mise à disposition des données dans une optique de libre accès.

2.2 Le standard IIIF

2.2.1 IIIF et les données ouvertes

Principes et objectifs

Le standard IIIF³⁴ est une initiative collaborative lancée en 2011 par un groupement d'institutions³⁵ attachées à faciliter la diffusion sur le Web des ressources iconographiques des collections patrimoniales³⁶. La volonté de développement de ce standard provient du constat que, malgré la nécessité d'un accès global aux images numériques pour la transmission du patrimoine culturel, un grand nombre de ces ressources restent, sur Internet, isolées dans des silos d'informations dont l'accès n'est possible que par des applications spécifiques à chaque institution³⁷, rendant complexe le partage et la mise en commun des ressources.

De cette observation est née la volonté de créer un outil proposant des méthodes standardisées de partage sur le Web des images et de leurs métadonnées, pour toute institution qui souhaiterait partager numériquement ses collections. IIIF propose ainsi un standard dont les fonctionnalités vont au-delà de celles d'un navigateur, capable d'afficher des formats libres d'image³⁸, sans proposer plus d'interaction avec les images servies³⁹. IIIF propose ainsi des outils interopérables, libres d'accès, permettant notamment de zoomer en profondeur sur les images, d'y appliquer des traitements visuels simples, de reconstruire la structure du document ou de les annoter.

Pour assurer ces fonctionnalités, IIIF s'appuie sur deux API : l'API Image et l'API Présentation. Ces API sont le socle du standard, elles en assurent la cohérence afin que les images puissent être partagées de manière fluide entre les institutions et projets. Le cœur du standard IIIF, qui fait tout son intérêt dans le contexte décrit précédemment du partage des images sur le Web, est en effet l'interopérabilité : IIIF assure ainsi la portabilité

34. IIIF

35. Les collaborateurs à l'initiative du projet sont la British Library, la BnF, Stanford University, les Bodleian Libraries, la Bibliothèque nationale de Norvège, la Bibliothèque nationale de Los Alamos et Cornell University.

36. Tom Cramer, *The International Image Interoperability Framework (IIIF) : Laying the Foundation for Common Services, Integrated Resources and a Marketplace of Tools for Scholars Worldwide*, déc. 2011, URL : <https://www.cni.org/topics/information-access-retrieval/international-image-interopability-framework> (visité le 08/08/2023).

37. *Ibid.*

38. IIIF propose également, depuis 2020, un service dédié aux fichiers vidéo, que nous n'abordons pas dans ce mémoire car les projets étudiés portent tous sur des images fixes.

39. *How It Works*, URL : <https://iiif.io/get-started/how-iiif-works/> (visité le 08/08/2023).

entre les visualiseurs, pour permettre une transmission réellement fluide de l'information.

Les API IIIF

Le fonctionnement du standard IIIF s'appuie sur deux éléments essentiels : l'envoi des images depuis les serveurs, et leur visualisation.

L'API Image définit les spécifications pour un service renvoyant une image en réponse à une requête HTTP (*Hypertext Transfer Protocol*) ou HTTPS (*Hypertext Transfer Protocol Secure*) : à partir d'une URI (*Uniform Resource Identifier*) valide, l'image peut être affichée dans un visualiseur, ou dans un navigateur. L'URI peut spécifier, dans sa requête, la région, la taille, la rotation, la qualité ou le format de l'image demandée, suivant des instructions spécifiques prédéfinies par le standard⁴⁰. En ajustant les paramètres, l'utilisateur peut ainsi obtenir une image qu'il peut modifier en accord avec ses besoins sans passer par un éditeur spécifique. L'API Image, développée pour des clients tels que les applications d'institutions patrimoniales, peut être implémentée sans l'API Présentation : seule, elle permet notamment un zoom rapide et profond sur des images en très haute résolution.

L'API Présentation permet d'introduire des fonctionnalités plus vastes en termes d'informations liées aux images : par le biais d'un manifeste au format JSON (*JavaScript Object Notation*), elle attache aux images des métadonnées descriptives, administratives et structurelles qui définissent la manière dont elles seront présentées dans un visualiseur. Le manifeste permet notamment de rassembler en un fichier les différents éléments d'un objet IIIF⁴¹, et notamment les séries d'images⁴², tout en gérant également leur ordre dans le document numérique. Le manifeste contient généralement des informations d'identification de l'objet original⁴³, et peut être enrichi d'annotations sur l'objet ou son contenu⁴⁴.

Pour afficher les images et les informations liées, il existe une multitude de visualiseurs⁴⁵ aux fonctionnalités différentes, tous compatibles avec tous les manifestes IIIF, quelle que soit leur institution d'origine. Ainsi, les ressources produites par les institutions peuvent être consultées par le biais d'outils libres, accessibles à tous. Pour aller au-delà des fonctionnalités proposées par les deux API centrales du standard, quatre autres API ont été développées, pour gérer d'autres besoins liés à mise à disposition d'images tout en respectant des principes standardisés⁴⁶.

40. *Image API 3.0*, URL : <https://iiif.io/api/image/3.0/> (visité le 08/08/2023).

41. *How It Works...*

42. Cette fonctionnalité est particulièrement intéressante pour les numérisations d'ouvrages, puisqu'elle permet de regrouper en un fichier toutes les pages numérisées.

43. On retrouve notamment le titre, l'auteur, l'institution de conservation, le numéro d'inventaire ou la cote, et les informations sur les droits de diffusion.

44. *Presentation API 3.0*, URL : <https://iiif.io/api/presentation/3.0/> (visité le 08/08/2023).

45. *IIIF Viewers*, URL : <https://iiif.io/get-started/iiif-viewers/> (visité le 08/08/2023).

46. *How It Works...*

Anatomie d'un manifeste

Pour constituer les éléments retournés par les API IIIF, il existe un modèle de données spécifique, qui assure la caractérisation des objets selon des normes communes, qui permettent de conserver l'interopérabilité du standard. Il existe ainsi des types de ressources, ou classes, précisément définies, avec une hiérarchie fixe (fig. 2.1), qui permettent de décrire les objets numérisés au format JSON.

Un manifeste est un fichier au format JSON. Du point de vue de la donnée, la classe *Manifest* permet de décrire un objet composé, une œuvre dans sa totalité : elle contient ainsi un ensemble de métadonnées descriptives la concernant (titre, auteur, institution de conservation, licence), et permet, si nécessaire, de reconstituer la structure de l'objet à partir des *Canvases*.

Le *Canvas* est un conteneur de niveau inférieur au *Manifest*, qui permet de représenter une vue spécifique d'un objet, et les métadonnées qui y sont associées. Si nécessaire, un élément de niveau supérieur peut exister entre les *Canvases* et le *Manifest* : il s'agit des *Ranges*, qui permettent de décrire une séquence de *Canvases*.

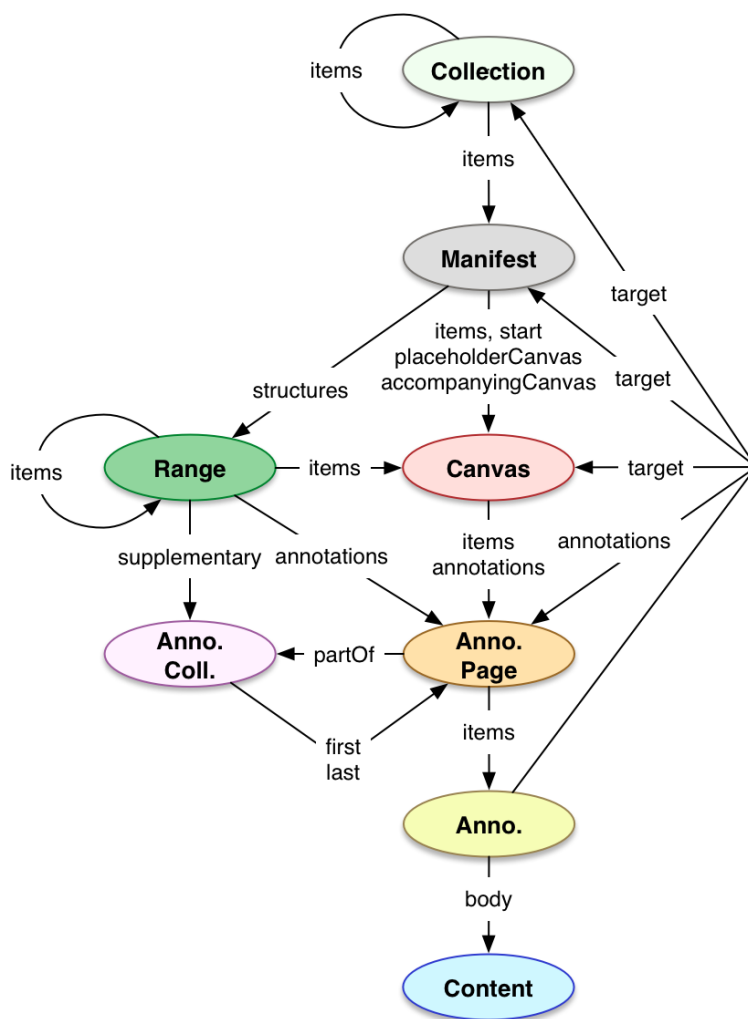


FIGURE 2.1 – Modèle de données IIIF pour la description d'un objet

Il existe, à un niveau supérieur au *Manifest*, une classe *Collection*, qui assure une plus grande flexibilité du modèle pour les projets qui souhaiteraient réunir plusieurs objets dans une catégorie plus large. Une *Collection* peut représenter une liste de *Manifests*, ou une liste de *Collections*, permettant ainsi de regrouper des objets ou groupes d'objets selon un cadre défini, qui facilite la navigation dans un ensemble restreint de ressources liées⁴⁷.

Pour un manifeste ne contenant que des images et leurs métadonnées, ces éléments suffisent à construire un fichier cohérent et fonctionnel, qui pourra être lu par un visualiseur IIIF.

Pour annoter les images d'un manifeste, il existe une série de types de ressource additionnels qui contiennent les annotations selon une hiérarchie précise, et les rattache à un *Canvas* spécifique. L'*Annotation Page* contient une liste ordonnée d'*Annotations* pour un *Canvas* : pour annoter un manifeste, il existe donc autant d'*Annotation Pages* qu'il existe de *Canvases* annotés.

La classe *Annotation* fait le lien entre le contenu de l'annotation (*Content*) et le *Canvas*⁴⁸ : ce type de ressource permet d'assurer l'interopérabilité du modèle, puisqu'elle permet l'alignement des annotations et des images, y compris dans le contexte d'annotations produites par un utilisateur différent du créateur du manifeste. Ainsi, ce modèle de données permet la collaboration entre plusieurs utilisateurs à partir d'un manifeste produit par une institutions, et rend possible la réutilisation des images comme des manifestes dans des projets ultérieurs, avec la fluidité d'un modèle partagé, standard, qui ne nécessite aucun effort d'alignement entre institutions.

2.2.2 IIIF, un modèle universel ?

Limites de l'interopérabilité du standard

IIIF est ainsi pensé comme un standard universel permettant aux institutions et aux projets qui le souhaitent de partager leurs ressources, de les mettre à disposition en assurant la possibilité de leur réutilisation : dans une optique de science ouverte, IIIF permet de partager aisément les résultats de projets de recherche impliquant des images.

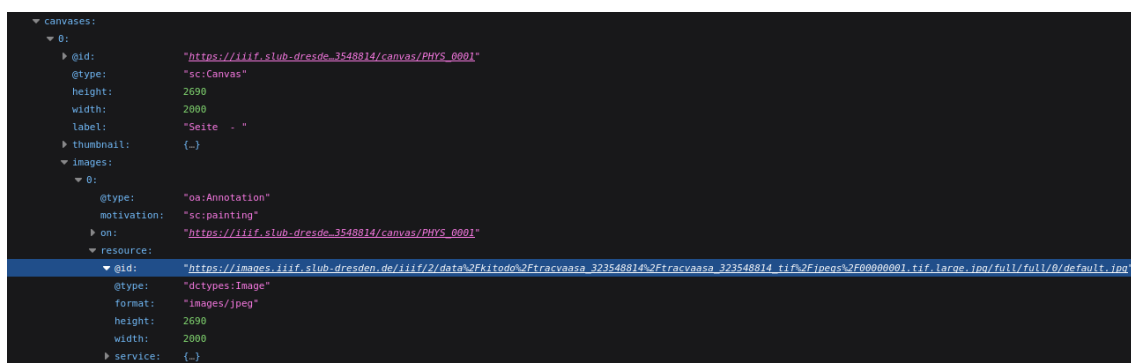
Cependant, malgré l'existence d'un modèle de données standard pour la description des objets, IIIF présente des limites dans son universalité. En effet, malgré son cadre construit pour assurer l'interopérabilité des manifestes, le modèle n'est en pratique pas employé de la même manière par toutes les institutions, et nécessite donc une adaptation des développements faits autour de IIIF pour prendre en compte ces exceptions. Nous constatons, par exemple, que si les ressources images sont supposées être intégrées au manifeste dans un conteneur *Canvas*, certaines institutions – comme la bibliothèque universitaire de

47. *Presentation API 3.0...*

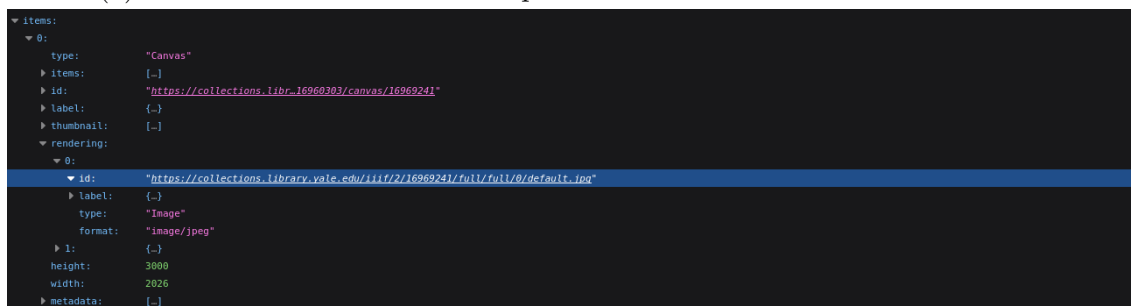
48. *Ibid.*

Yale – utilisent plutôt des *Items* (fig. 2.2), modifiant ainsi profondément la structure du manifeste IIIF tout en conservant un fichier lisible par les visualiseurs. L’application du standard varie ainsi d’une institution à l’autre, sans altérer le fonctionnement des outils de base de IIIF, mais en provoquant cependant une déperdition de son universalité pour des projets qui souhaiteraient développer des outils autour de ces manifestes.

Dans un projet reposant sur l’exploitation d’images d’objets patrimoniaux, tels que les projets décrits dans ce mémoire, il est ainsi nécessaire de prendre en compte ces exceptions techniques : dans le cadre du projet EIDA, la récupération des images est effectuée par un algorithme spécifique⁴⁹, qui parse un manifeste IIIF déposé par un utilisateur dans l’application du projet et en extrait des fichiers images pour les enregistrer. Dans le développement de cet algorithme, il a ainsi été nécessaire de prendre en compte les exceptions possibles, pour ne pas créer d’erreur en cas de dépôt d’un manifeste à la structure différente.



(a) Manifeste IIIF de la bibliothèque universitaire de Dresde avec *Canvases*



(b) Manifeste IIIF de la bibliothèque universitaire de Yale avec *Items*

FIGURE 2.2 – Comparatif des ressources contenant les images de deux manifestes IIIF

Implémentation de IIIF : un réflexe global ?

Pour les projets de recherche exploitant des images respectant le standard IIIF, il se pose la question des institutions ayant fait le choix de gérer leurs images différemment. En effet, si de nombreuses institutions ont adopté le standard et mis en ligne des centaines de

49. *Iiif-Downloader*, URL : <https://github.com/Segolene-Albouy/iiif-downloader/tree/main> (visité le 09/08/2023).

millions d'images compatibles depuis la naissance de l'initiative⁵⁰, il n'est ni obligatoire ni systématique, et il reste ainsi un nombre certain d'établissements qui gèrent leurs images avec des outils techniques différents, et restent ainsi exclus du standard. Les musées, notamment, et particulièrement les musées hors Amérique du Nord, exploitent encore peu les possibilités offertes par IIIF en termes de partage des images⁵¹, et restent en marge de cette initiative de facilitation de la mise en commun et de l'exploitation des ressources iconographiques.

Il n'est cependant pas envisageable, dans le cadre d'un projet de recherche, d'exclure totalement les sources provenant d'institutions n'utilisant pas le standard IIIF : il est donc nécessaire, dans le développement d'outils numériques pour la gestion des images, de prendre en compte ces sources aux formats différents, qu'il faut traiter pour les rendre exploitable de la même manière que le sont les images extraites de manifestes IIIF. Ainsi, dans la chaîne de traitement des images, une réflexion doit être menée pour l'intégration d'autres formats, tels que les PDF pour les numérisations d'ouvrages, ou les fichiers image indépendants. Malgré la fluidité du traitement des sources permise par l'existence d'un standard, il est ainsi nécessaire de réfléchir à des solutions techniques au-delà des limites de ce dernier, pour ne pas exclure des corpus les sources numérisées présentant un intérêt pour la recherche.

Dans un projet de recherche en vision artificielle, l'utilisation du standard IIIF permet, d'une part, la constitution aisée d'un corpus d'images, qu'il est possible de récupérer directement sur les sites des institutions à l'aide des API : le standard IIIF fluidifie fortement les échanges et la réutilisation des documents numérisés, et permet de construire un outil générique pour le traitement de sources numériques provenant d'institutions diverses. Il reste cependant de nombreux cas où une chaîne de traitement parallèle doit être développée, pour pallier à l'absence d'implémentation du standard dans certaines institutions. D'autre part, l'utilisation du standard IIIF pour la publication en ligne des données du projet permet également d'envisager leur réutilisation future par d'autres initiatives, en s'assurant de l'interopérabilité des résultats produits, dans une démarche de science ouverte.

Les sources iconographiques sont soumises à un ensemble de restrictions, du point de vue du format, des métadonnées ou des droits, qui manquent encore d'une uniformité internationale et entre institutions qui rendrait fluide le partage de ces ressources sur Internet et entre les projets de recherche. Dans un projet impliquant l'utilisation d'algorithmes de vision artificielle, qui repose alors sur le traitement d'un volume important d'image, la mise en ligne de ces documents est un enjeu crucial, sur lequel repose d'une part la

50. Gavin Mallory, *IIIF for Museums, Explained*, juill. 2019, URL : <https://blog.cogapp.com/iiif-for-museums-explained-49fd0560e1ba> (visité le 09/08/2023).

51. *IIIF for Museums in France*, juill. 2023, URL : <https://www.culture.gouv.fr/en/Thematic/Museums/Pour-les-professionnels/Network/IIIF-for-museums-in-France> (visité le 09/08/2023).

possibilité de constituer un corpus exploitable, ainsi que la publication des résultats du projet, qui peuvent également prendre la forme d'images numériques. Dans une optique de science ouverte, l'utilisation de standards et d'outils tels que ceux développés par le consortium IIF permet d'assurer le partage d'images et de données respectant les mêmes formats, exploitables avec des outils libres, et d'avancer vers une abolition des silos de données, qui faciliterait notamment la construction de corpus massifs pour l'apprentissage machine.

Chapitre 3

Corpus historiques et jeux de données pour l'apprentissage machine

La vision artificielle et l'apprentissage machine permet le traitement de corpus d'images massifs par des méthodes quantitatives qui permettent aux historiens de traiter un volume de données bien plus important qu'une approche manuelle, ouvrant ainsi la voie à de nouvelles approches. Cette partie revient sur les bonnes pratiques à mettre en place afin d'assurer la pertinence de l'utilisation de ces outils, et d'en faire des traitements efficaces en accord avec les ambitions des projets.

3.1 Dimensions et cadre

3.1.1 La tentative de l'exhaustivité

Représentativité et pertinence

L'approche computationnelle de corpus de sources historiques permet le traitement d'un volume d'images inenvisageable sans automatisation, qui redéfinit ainsi le rôle des chercheurs comme les méthodes de constitution d'un corpus, pour prendre en compte cette quantité de données qu'il est possible de considérer à l'aide d'outils numériques¹. L'apprentissage profond permet d'envisager une redéfinition des méthodes des historiens et historiens de l'art, en intégrant une part d'automatisation dans le traitement des sources iconographiques, permettant ainsi d'envisager l'exploration de corpus bien plus vastes²

1. Harald Klink, « Big Image Data within the Big Picture of Art History », *International Journal for Digital Art History*-2 (oct. 2016), DOI : 10.11588/dah.2016.2.33527.

2. Eleonora Moiraghi et Jean-Philippe Moreux, *Explorer des corpus d'images. L'IA au service du patrimoine*, Billet, avr. 2018, URL : <https://bnf.hypotheses.org/2809> (visité le 06/08/2023).

par des méthodes quantitatives³.

Dans le cadre du projet EIDA, ces possibilités ouvertes par l'intégration de techniques de vision artificielle dans le traitement du corpus permet ainsi d'envisager des bornes larges, définies précédemment, sur le plan géographique comme chronologique, tout en assurant un traitement d'un grand nombre de sources – plusieurs centaines ou milliers d'images – pour chaque contexte étudié.

Le projet VHS s'appuie également grandement sur la vision artificielle appliquée à la détection de similarité, dans le cadre d'une étude de la circulation des savoirs scientifiques par le biais de l'illustration : les corpus constitués pour le projet ont donc été pensés pour offrir un regard pertinent sur ces questions, et sélectionnés avec une volonté de représentativité géographique, chronologique et thématique⁴. Leur analyse portera ainsi sur un ensemble de plus de 10000 images d'animaux, de plantes et de minéraux.

Ainsi, l'intégration au cadre des projets de méthodes de vision artificielle permet d'envisager l'étude de corpus larges, vastes, et de porter un regard sur des zones géographiques larges, sur des périodes étendues, avec la possibilité de traiter des corpus massifs par des approches quantitatives développées en collaboration avec les historiens.

Données d'entraînement

Au-delà de la pertinence du corpus pour un projet de recherche donné, il est nécessaire, pour l'entraînement d'un modèle de vision artificielle, de prévoir un fragment du corpus dédié à la constitution d'un ou de plusieurs jeux de données d'entraînement⁵. La représentativité est un élément clé de ces corpus restreints, qui doivent à leur échelle comporter suffisamment de cas d'études différents pour englober les situations rencontrées dans le corpus global, et ainsi produire un modèle apte à appréhender toutes les situations rencontrées dans un contexte d'inférence. Un dialogue entre les chercheurs et les ingénieurs est alors nécessaire, pour établir les besoins d'un point de vue technique comme d'un point de vue scientifique, afin d'obtenir en finalité un outil performant, apte à traiter le corpus du projet. Les chercheurs ayant une connaissance scientifique de la typologie des sources rencontrées dans le cadre du projet, ils sont ainsi à même d'estimer la diversité des images que rencontrera le modèle, et donc de construire un jeu de données d'entraînement représentatif et pertinent, en accord avec les bornes définies du projet.

Le projet EIDA, dont le cadre géographique s'étend de l'Europe à l'Asie, du VIII^e au XVIII^e siècle, est ainsi vaste en termes de sources historiques et de diagrammes repré-

3. H. Klinke, « Big Image Data within the Big Picture of Art History »...

4. *Corpus*, URL : <https://vhs.hypotheses.org/corpus> (visité le 09/08/2023).

5. Un jeu de données d'entraînement comptant en général plusieurs centaines d'exemples, il est possible, à cette étape, d'évaluer la pertinence véritable du développement d'un modèle dédié au traitement du corpus global du projet. Daniel van Strien, Kaspar Beelen, Melvin Wevers, Thomas Smits et Katherine McDonough, « Computer Vision for the Humanities : An Introduction to Deep Learning for Image Classification (Part 1) », *Programming Historian* (, août 2022), URL : <https://programminghistorian.org/en/lessons/computer-vision-deep-learning-pt1> (visité le 10/08/2023)

sentés. Les jeux de données d’entraînement doivent être représentatifs d’un point de vue thématique, en proposant des diagrammes aux formats et apparences diverses, en accord avec les typologies variées retrouvées dans le corpus ; mais ceux-ci doivent aussi prendre en compte la diversité des supports. Le corpus d’EIDA comporte en effet des sources manuscrites comme des sources imprimées, qu’il est donc nécessaire de traiter conjointement. Il a été envisagé, pour des questions de performance, de produire un modèle de vision entraîné spécifiquement sur des sources manuscrites, et un second modèle entraîné sur des sources imprimées, afin de dissocier totalement le traitement de ces deux supports dans l’application finale⁶. Dans un corpus aussi varié linguistiquement que celui du projet EIDA, il est également crucial de sélectionner un jeu de données d’entraînement diversifié du point de vue des langues, pour s’assurer de l’efficacité du modèle sur des sources aux provenances diverses : nous constatons en effet que les premières détections faites avec des modèles de détection pré-entraînés⁷ sont satisfaisantes sur des sources latines ou grecques, mais qu’ils performant peu efficacement sur des sources chinoises, où chaque idéogramme est détecté comme une image.

Ainsi, l’automatisation d’une partie de la chaîne de traitement des sources permet, de construire un corpus de recherche vaste en offrant l’opportunité d’analyser un volume massif de sources historiques : ces possibilités sont particulièrement intéressante dans le cadre de projets de recherches inscrits dans l’histoire de la circulation des idées, des images et des théories, puisque les corpus construits peuvent être représentatifs de multiples cadres géographiques, temporels et thématiques, sans craindre un surplus de sources à traiter. Pour construire des outils pertinents pour le traitement de ces corpus massifs, il est cependant nécessaire d’avoir un regard global sur leur contenu, pour reproduire à moindre échelle leur représentativité dans des jeux de données d’entraînement, nécessaires au développement de modèles de vision artificielle pertinents pour des sources étudiées.

3.1.2 Automatiser le traitement de corpus massifs

Possibilités de la *computer vision*

La vision artificielle offre, pour le traitement de ces larges corpus, la possibilité d’automatiser certaines étapes spécifiques qui interviennent en parallèle d’étapes d’analyse par les chercheurs. Il n’existe ainsi pas de *workflow* totalement automatisée, où l’historien n’interviendrait pas dans le traitement des sources étudiées. En effet, l’intégration de la vision artificielle aux méthodes des historiens n’existe que conjointement à des interventions humaines, qui assurent la pertinence des traitements effectués et apportent une analyse nécessaire.

6. L’entraînement des modèles de détection d’objet n’ayant pas encore été effectué, il est actuellement impossible de tirer des conclusions quant à la pertinence de ce choix.

7. Nous traitons de ces modèles dans la partie II.1.2.

L'une des premières applications de la vision par ordinateur exploitée dans les projets étudiés est la détection d'objets dans les images : pour le traitement de sources numérisées, la détection d'objets présente des applications diverses. Il s'agit, le plus souvent, de la première étape d'une chaîne de traitement ; permettant, par exemple, dans l'étude de sources manuscrites ou imprimées contenant du texte et des illustrations, d'extraire les images présentes dans ces sources⁸. Dans les projets EIDA et VHS, cette étape de détection des images dans les ouvrages est faite dans une optique de segmentation des pages, pour en extraire les illustrations qui seront ensuite traitées par d'autres algorithmes de vision, tels que des algorithmes de détection de similarité ou de vectorisation. D'autres projets, cependant, proposent dès l'étape de détection une classification des illustrations par typologie, pour permettre une première analyse et un premier regard sur la place de ces objets détectés dans les sources étudiées : l'application *CorDeep*⁹, développée par le Max Planck Institute for the History of Science en partenariat avec BIFOLD pour l'extraction d'éléments visuels dans les sources historiques, propose de classer les illustrations détectées en quatre catégories¹⁰, appliquant dès la détection un premier traitement pour l'analyse des illustrations par les chercheurs, qui peuvent ainsi plus aisément naviguer des corpus de numérisations d'ouvrages par le biais des images.

La détection de similarité compte parmi les applications les plus directes du *deep learning*¹¹ : il est possible, à l'aide d'un modèle entraîné sur un jeu de données restreint, d'effectuer sans supervision des comparaisons entre toutes les images du corpus, pour les réunir en séries ou groupes qui seront ensuite analysés par les historiens. Le développement d'un tel outil exemplifie les possibilités offertes par l'intelligence artificielle pour la navigation de gros corpus : elle permet de classer les images en vue de leur étude en constituant des séries iconographiques aux caractéristiques visuelles similaires, selon un score de similarité calculé par l'algorithme. Dans le cas d'une étude des circulations des illustrations scientifiques, la constitution de ces séries permet aux chercheurs d'effectuer une analyse sur l'évolution des théories scientifiques, par le regroupement d'images de traditions différentes présentant des éléments similaires. L'automatisation de cette étape permet ainsi de tracer des parallèles entre un grand nombre d'image, en lançant la détection sur des corpus très larges qu'il serait difficile de traiter manuellement.

La *computer vision* permet également d'envisager des traitements pour l'édition, et particulièrement dans le cas d'objets scientifiques tels que les diagrammes, dont la mise en forme est un questionnement à part entière pour l'édition des textes qu'ils illustrent. La détection de contours (ou *edge detection*) est une étape fondamentale pour le traitement

8. Jochen Büttner, Julius Martinetz, Hassan El-Hajj et Matteo Valleriani, « CorDeep and the Sacrobosco Dataset : Detection of Visual Elements in Historical Documents », *Journal of Imaging*, 8–10 (oct. 2022), p. 285, DOI : 10.3390/jimaging8100285.

9. *CorDeep*, URL : <https://cordeep.mpiwg-berlin.mpg.de/> (visité le 10/08/2023).

10. *Content Illustrations, Initials, Decorations et Printer's Marks*.

11. E. Moiraghi et J.P. Moreux, *Explorer des corpus d'images. L'IA au service du patrimoine...*

des images en vision artificielle : combinée à des méthodes de détection des lignes¹², il devient envisageable d'automatiser la transformation d'images au format .tiff ou .jpeg en objets plus aisément manipulables, et notamment la transformation vers le SVG (*Scalable Vector Graphics*), qui fait alors des diagrammes des objets édités et éditables, exploitables par les chercheurs en tant qu'objets numériques.

Diversité des traitements, diversité des données

Pour ces divers traitements exploitant la vision artificielle, l'étape d'entraînement est nécessaire pour l'obtention d'un modèle efficace sur les données du projet, et pour que celui-ci performe en accord avec les tâches qui lui sont demandées. L'entraînement d'un modèle nécessite généralement plusieurs étapes¹³, et par conséquent autant de jeux de données qu'il y a d'étapes : il est de bonne pratique de prévoir un jeu de données initial, et d'évaluer les performances du modèle après ce premier entraînement. À partir de ces résultats, il devient possible d'adapter les jeux de données suivants, pour pallier aux faiblesses constatées. De plus, si le format des données d'entraînement nécessaires varie en fonction des tâches effectuées par le modèle¹⁴, les exigences en termes de volume et de représentativité varient également.

Pour des tâches classiques de vision artificielle, telles que la détection d'objets, des modèles pré-entraînés performants existent en libre accès, qui ne nécessitent donc pas autant de travail d'entraînement qu'un modèle créé dans son entièreté pour un projet. Des jeux de données en accès libre sont également disponibles pour l'entraînement de modèles pour la détection automatique, tels que ImageNet¹⁵, qui bien qu'ils ne soient pas adaptés à des sources historiques, permettent d'effectuer un premier entraînement d'un modèle sans mobiliser les moyens nécessaires à la création d'un jeu de données. Les algorithmes de détection de similarité ou de vectorisation, cependant, ne sont pas aussi développés que ces algorithmes de détection d'objets, et nécessitent donc un volume de données plus important, que les projets se doivent de fournir pour la création de modèles performants.

Ainsi, pour un projet d'humanités numériques faisant appel aux méthodes de la vision artificielle, il est nécessaire d'apporter une réflexion, en premier lieu, sur la pertinence de l'usage de l'intelligence artificielle pour le traitement du corpus – pertinence souvent relative au volume de données à traiter. Il est ensuite nécessaire, au-delà des sources du projet, de penser les données pour le *deep learning*, en prenant en compte l'importance

12. Xinyu Lin, Yingjie Zhou, Yipeng Liu et Ce Zhu, *A Comprehensive Review of Image Line Segment Detection and Description : Taxonomies, Comparisons, and Challenges*, avr. 2023, DOI : 10.48550/arXiv.2305.00264, arXiv : 2305.00264 [cs].

13. D. van Strien, K. Beelen, M. Wevers, *et al.*, « Computer Vision for the Humanities... ».

14. Les cas varient en fonction du format des données d'entrée et de sortie : images au format .jpeg et annotations au format .txt pour la détection, images au format .jpeg et images au format .svg pour la vectorisation, etc.

15. *ImageNet*, URL : <https://www.image-net.org/> (visité le 10/08/2023).

d’avoir des jeux de données qualitatifs et représentatifs pour la création d’un modèle efficace pour l’automatisation des tâches souhaitées. Les formats, typologies, volumes de ces jeux de données d’entraînement, souvent multiples, est ainsi à considérer en collaboration entre les équipes d’ingénierie et de recherche, pour prendre en considération les besoins vis-à-vis du contenu du corpus, tout en ne perdant pas de vue les besoins techniques liés à l’entraînement d’un modèle de vision par ordinateur.

3.2 Objectifs scientifiques et possibilités numériques

3.2.1 Dialogue entre chercheurs et ingénieurs

Concilier les besoins

L’intégration de traitements employant l’intelligence artificielle a des projets de recherche en humanités implique une redéfinition des méthodes, pour adapter les pratiques des chercheurs aux nouveaux besoins soulevés par ces techniques. Dans la section précédente, nous avons établi les nécessités et possibilités liées aux corpus de recherches, mais il est également crucial de prendre en compte les échanges entre les acteurs divers impliqués dans de telles initiatives. Les projets étudiés dans le cadre de ce mémoire – notamment les projets EIDA et VHS – présentent une architecture similaire en termes d’équipes impliquées : il est, d’une part, une équipe d’historiens¹⁶ menant des recherches sur les thèmes étudiés, travaillant en collaboration avec une équipe de chercheurs en vision artificielle¹⁷. Les équipes d’histoire des sciences comptent, dans le cas de VHS et EIDA, un ou plusieurs ingénieurs, chargés de développement spécifiques et d’établir la communication avec les équipes de vision.

Les deux équipes de recherche impliquées dans les projets font ainsi face à des besoins variés, qui ne sont pas nécessairement alignés. La communication établie entre ces deux pôles permet de clarifier les besoins en termes de traitement des sources historiques, par opposition aux besoins en termes de techniques, et particulièrement de définir les limites de ces méthodes et techniques numériques appliquées à l’histoire. Il se dessine alors une tension entre les attentes vis-à-vis des modèles de vision, et les possibilités réelles de la technique, qu’il est crucial de prendre en compte pour le développement d’outils à la fois performants et pertinents.

16. Composée de chercheurs permanents, de chercheurs affiliés, de chercheurs postdoctorants et de doctorants.

17. Dans les deux cas cités, il s’agit de l’équipe dirigée par Mathieu Aubry, appartenant au groupe de recherche IMAGINE.

Utilité pour le *machine learning* et intérêt historique

Ces tensions entre les besoins se manifestent dès les premières étapes de développement d'un modèle de vision artificielle : dans le cas du projet EIDA, porté sur la détection de diagrammes dans les manuscrits, la confrontation entre l'aspect binaire de la détection et les nuances que doivent présenter l'approche historique se présente dès l'étape de constitution d'un premier jeu de données d'entraînement. En effet, cet aspect binaire du modèle, qui s'appuie sur l'opposition entre ce qui est un diagramme et ce qui n'en est pas un – et plus largement, ce qui est une objet à détecter et ce qui n'en est pas un – ne peut prendre en compte les cas limites qui se présentent systématiquement avec des sources historiques provenant d'un corpus aussi large. Se pose ainsi la question de la conciliation de ces deux exigences visiblement opposées : il est nécessaire de décider, par une discussion entre l'équipe de vision artificielle et l'équipe d'histoire des sciences, de ce qui est bel et bien un diagramme, selon les possibilités techniques et les besoins historiques.

Une distinction se crée entre les pratiques utiles pour le *deep learning* et les éléments intéressants pour les historiens. L'objectif, pour les deux équipes, est en effet de construire un outil utile aux résultats exploitables ; les projets ont donc pour devoir de prendre en compte ces besoins divergents, et d'établir un juste milieu entre les possibilités offertes et les objectifs initiaux.

Ainsi, dans cette situation, un équilibre est défini entre performances du modèle et pertinence historique, en prenant en compte le fait qu'il existe, après la détection, une intervention humaine : aucune solution n'étant pleinement satisfaisante, il convient de décider de celle qui permet de concilier les possibilités techniques et les objectifs scientifiques, afin de créer un outil qui produit des données exploitables, et qui automatise de manière pertinente le traitement des sources. Dans cette démarche, il est nécessaire de donner un cadre strict aux pratiques pour assurer une uniformisation des données, premier critère pour le développement d'outils numériques efficaces aux résultats cohérents.

3.2.2 Définir les pratiques


Traiter les cas limites

Il existe autant de manière de gérer ces situations qu'il existe de projet : les pratiques sont à définir en accord avec les besoins de chaque projet, sans qu'il n'existe de solution universelle. Les normes à appliquer sont à établir par un dialogue prenant en compte les ambitions techniques et scientifiques de chaque projet, ainsi que les spécificités des sources étudiées, qui présenteront des caractéristiques spécifiques propres à chaque corpus.

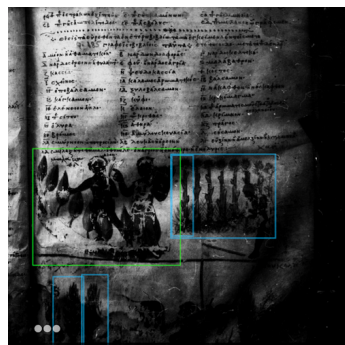
En amont de la constitution du jeu de données pour l'entraînement du modèle de détection des diagrammes astronomiques du projet EIDA, cette discussion entre l'équipe de l'Observatoire et celle du laboratoire IMAGINE a mené à la décision d'annoter tout type

de diagramme, ainsi que les illustrations retrouvées dans les manuscrits, même lorsqu’elles ne correspondent pas aux objets recherchés. En effet, l’exclusion d’illustrations telles que les miniatures dans les données d’entraînement – même si ces dernières ne correspondent pas aux objectifs scientifiques du projet – pourrait produire un modèle aux détections lacunaires. La solution choisie l’a été en prenant en considération le fait qu’il est plus aisé pour un historien qui analyserait les images détectées d’exclure les illustrations qui ne sont pas des diagrammes, plutôt que de rechercher dans la numérisation des diagrammes manqués par un modèle aux performances insatisfaisantes.


La création d’un premier jeu de données pour l’entraînement d’un modèle dédié à la détection des illustrations dans le corpus de VHS a permis de mettre en lumière un certain nombre de cas limites, ou *edge cases*, qui correspondent techniquement aux pratiques d’annotation définies par le projet, mais qui néanmoins impacteraient négativement les performances du modèle. Ainsi, nous voyons dans les annotations réalisées par les chercheurs de VHS des pratiques à modifier (fig. 3.1). Dans le premier cas, toutes les illustrations de la page n’ont pas été annotées : seule l’image principale de la planche zoologique est annotée comme un objet à détecter, tandis que les plus petites images sont délaissées. Comme mentionné précédemment, l’aspect manichéen de la détection par vision artificielle ne permet pas de hiérarchiser ainsi les images considérées intéressantes pour la recherche, et celles qui ne le sont pas, il est donc nécessaire d’annoter l’ensemble des illustrations pour ne pas impacter négativement les performances du modèle, et risquer une détection lacunaire. Dans les deuxièmes et troisièmes cas, les images annotées n’auraient pas dû l’être, car si la mauvaise qualité de la numérisation ou l’aspect fragmenté du document n’empêche pas un observateur humain d’identifier les illustrations comme telles, il est une part de reconstitution des pans manquants de l’image qui tient de l’interprétation, et qui ne peut donc être attendue d’un modèle de vision artificielle. L’annotation de ce type d’objets pour l’entraînement du modèle risquerait ainsi d’altérer ses performances, en le poussant à détecter comme des illustrations des éléments qui n’en seraient pas.



(a) Annotation incomplète des illustrations



(b) Annotation d’un document mal numérisé



(c) Annotation d’un document lacunaire

FIGURE 3.1 – Cas limites rencontrés lors de l’annotation des images du projet VHS

Ces décisions quant à l’annotation sont ainsi prises suite à un dialogue entre les équipes de chercheurs en vision et d’historiens, pour trouver un juste équilibre entre attentes et possibilités réelles. Des choix sont faits pour tirer parti des méthodes de vision artificielle, tout en acceptant que leurs résultats ne seront jamais identiques à ceux d’un travail manuel : les décisions doivent ainsi être prises pour exploiter de manière pertinentes ces techniques. Les pratiques définies par ces discussions entre les équipes mènent à des normes d’annotation : des spécifications sont alors rédigées pour les établir, et s’assurer de leur application uniforme, pour la création de données cohérentes.

Guides des pratiques : établir les normes

Pour s’assurer de l’application uniforme des normes d’annotation, il est de bonne pratique de rédiger une documentation à destination des chercheurs, à laquelle chacun peut se référer lors des étapes de création des données d’entraînement, qui constituent en elles-mêmes un travail considéré comme travail de recherche, puisqu’il requiert une connaissance et une compréhension des sources. Ainsi, les données produites suivent les mêmes règles, et cette cohérence assure une uniformité de jeu de données fourni au modèle de vision : cette uniformité permet, s’il une nouvelle étape d’entraînement est nécessaire, de corriger plus facilement les choix ayant mené à des résultats non-satisfaisants.

Les chercheurs du projet EIDA se sont vus fournir un *Annotation Tutorial* en anglais, rédigé par Ségolène Albouy, cheffe de projet numérique, et Jil Le Bois, stagiaire de licence. Cette documentation fait suite à la mise en place d’une chaîne de traitement automatique des sources déposées par les chercheurs sur l’application du programme, qui produit une première détection que les chercheurs ont ensuite pour devoir de corriger. Le tutoriel qui a été communiqué contient des explications sur l’annotation dans l’application, avec un pas-à-pas détaillant chaque étape de ce travail, ainsi qu’une liste de cas pratiques établie en communication avec les historiens et l’équipe du laboratoire IMAGINE.

Les cas pratiques établis répondent – le plus souvent – à des questions posées par les historiens à l’équipe d’ingénierie à l’occasion d’ateliers ou de séminaires, qui permettent de souligner au préalable les possibles doutes qui seront rencontrés lors de l’annotation. L’*Annotation Tutorial* permet de garder trace de ces questionnements, et d’y apporter une réponse dont l’application sera systématique. La production de cette documentation, dont la responsabilité incombe aux ingénieurs d’étude, en tant que vecteurs de la communication entre les équipes d’histoire et de vision, pour donner à chaque parti impliqué la possibilité de se référer à un document qui rappelle les décisions prises. Cette possibilité de se référer à un document exhaustif est importante pour les étapes d’annotation, puisqu’elle garantit des données uniformes, mais aussi lors des étapes postérieures, notamment si d’autres entraînements sont nécessaires pour affiner les performances du modèle.

Le *deep learning* et la vision artificielle permettent aux projets de recherche en histoire

et en histoire de l'art d'envisager de nouvelles approches des sources, à l'aide de traitement automatisés qui offrent de nouvelles méthodes de navigation de corpus d'images massifs : de la détection à l'édition, les outils produits redéfinissent les étapes de traitement des sources, et il est ainsi nécessaire d'intégrer aux pratiques des chercheurs des méthodes spécifiques à ce type d'approche, et notamment pour la création de jeu de données d'entraînement, à la base du développement de tout modèle de *machine learning*. Cette intégration passe notamment par la rédaction de documentation, ainsi qu'un dialogue entre les équipes de recherche en vision artificielle et les équipes d'historiens. Ce dialogue permet d'établir les besoins de chacun, et de développer des outils techniques qui répondent aux besoins scientifiques de manière pertinente, en développant des modèles qui, malgré leurs limites, rejoignent aux mieux les attentes des sciences historiques.

Deuxième partie

De l'image à l'objet : intégrer
l'apprentissage profond au
traitement des sources historiques

Chapitre 4

Principes et méthodes de l'apprentissage profond

4.1 Réseaux de neurones et *computer vision*

4.1.1 Des « neurones » pour le machine learning

Sous-sous-section 1

Sous-sous-section 2

4.1.2 « Voir », comprendre et traiter les images

Sous-sous-section 1

Sous-sous-section 2

4.2 Modèles de vision *off-the-shelf* : outils libres pour la détection d'objets

4.2.1 YOLOv5, docExtractor et autres modèles

Sous-sous-section 1

Sous-sous-section 2

4.2.2 Entraînement et *fine-tuning*

Sous-sous-section 1

Sous-sous-section 2

Chapitre 5

L'interface entre chercheurs et algorithme : construire une plateforme pour la détection

5.1 Architecture de l'application : fonctionnalités et outils

5.1.1 Une interface pour le dépôt des sources

Sous-sous-section 1

Sous-sous-section 2

5.1.2 Décrire les sources

Sous-sous-section 1

Sous-sous-section 2

5.1.3 Images et objets détectés : une nouvelle source ?

Sous-sous-section 1

Sous-sous-section 2

5.2 Créer un outil open source : penser une application réutilisable

5.2.1 De VHS à EiDA : adapter un modèle de données

Sous-sous-section 1

Sous-sous-section 2

5.2.2 Construire une application réutilisable

Sous-sous-section 1

Chapitre 6

Intégrer l'apprentissage profond aux pratiques des chercheurs : le *workflow* de traitement des sources

6.1 Annoter sur un GPU : extractorAPI

6.1.1 Architecture du système

Sous-sous-section 1

Sous-sous-section 2

6.1.2 Cahier des charges et analyse des besoins

Sous-sous-section 1

Sous-sous-section 2

6.1.3 Programmation modulaire et *open source*

Sous-sous-section 1

Sous-sous-section 2

6.2 De la numérisation à l'annotation

6.2.1 *Workflow* d'annotation

Sous-sous-section 1

La chaîne de traitement proposée par EIDA (fig. 6.1) propose ainsi une alternance d'étapes automatisées, en bleu sur le schéma, et d'étapes d'analyse par les chercheurs du

projet.

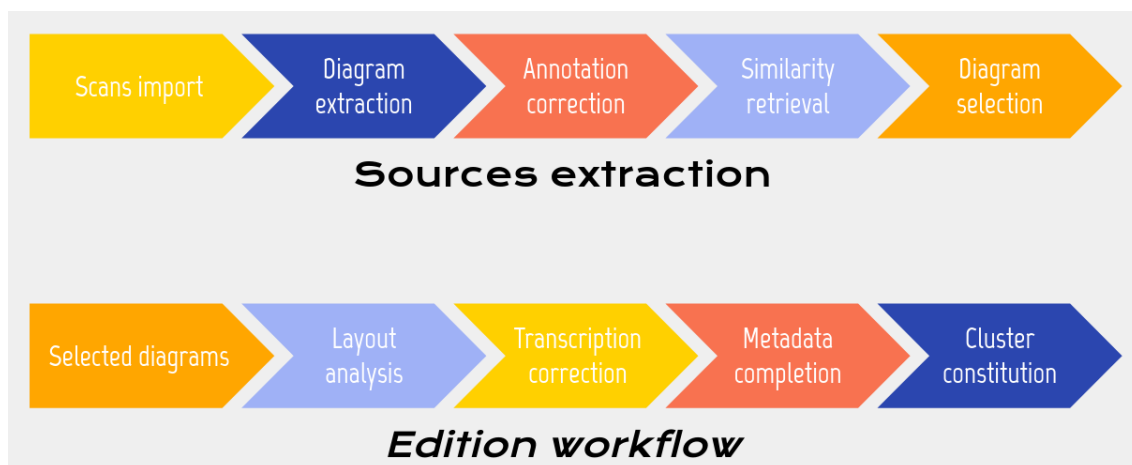


FIGURE 6.1 – *Workflow* de traitement des sources du projet EIDA

Sous-sous-section 2

6.2.2 Échanges et transformation des données

Sous-sous-section 1

Sous-sous-section 2

6.2.3 Interface d'annotation

Sous-sous-section 1

Sous-sous-section 2

6.3 Médiation et documentation

6.3.1 Séminaire DH et échanges avec les chercheurs

Sous-sous-section 1

Sous-sous-section 2

6.3.2 Documentation et Wiki : penser le réemploi du code

Sous-sous-section 1

Sous-sous-section 2

Troisième partie

Perspectives pour le traitement des
sources : vers un outil pour l'édition
et la recherche

Chapitre 7

Éditer des diagrammes : vectorisation et édition critique

7.1 Édition critique des diagrammes astronomiques

7.1.1 Historique

Sous-sous-section 1

Sous-sous-section 2

7.1.2 Éditer les diagrammes en format numérique

Sous-sous-section 1

Sous-sous-section 2

7.2 De l'image aux vecteurs : la vision artificielle pour l'édition numérique

7.2.1 Automatiser la transcription

Sous-sous-section 1

Sous-sous-section 2

7.2.2 Données d'entraînement et annotations pour la vectorisation

Sous-sous-section 1

Sous-sous-section 2

7.2.3 Diagrammes en SVG

Sous-sous-section 1

Sous-sous-section 2

Chapitre 8

Regroupement par similarité et *clustering*

8.1 *Similarity retrieval* et navigation des corpus

8.1.1 Principe et méthodes

Sous-sous-section 1

Sous-sous-section 2

8.1.2 Fouiller des corpus par l'image

Sous-sous-section 1

Sous-sous-section 2

8.2 Le *clustering* comme outil pour les chercheurs

8.2.1 Sous-section 1

Sous-sous-section 1

Sous-sous-section 2

8.2.2 Sous-section 2

Sous-sous-section 1

Sous-sous-section 2

8.2.3 Sous-section 3

Sous-sous-section 1

Sous-sous-section 2

Chapitre 9

Étudier et exploiter les résultats automatiques : limites et perspectives pour les sciences historiques

9.1 Titre section 1

9.1.1 Sous-section1

Sous-sous-section 1

Sous-sous-section 2

9.1.2 Sous-section 2

Sous-sous-section 1

Sous-sous-section 2

9.1.3 Sous-section 3

Sous-sous-section 1

Sous-sous-section 2

9.2 Titre section 2

9.2.1 Sous-section1

Sous-sous-section 1

Sous-sous-section 2

9.2.2 Sous-section 2

Sous-sous-section 1

Conclusion

Annexes

Liste des acronymes

- API *Application Programming Interface*. 17, 21–23, 26
- CSV *Comma-separated values*. 6
- DIPS *DISHAS Interactive Parameter Squeezer*. 5
- DISHAS *Digital Information System for the History of Astral Sciences*. 4–7, 11
- DTI *DISHAS Table Interface*. 5
- EIDA *Editing and analysing hIstorical astronomical Diagrams with Artificial intelligence*. 3–8, 11, 12, 16, 25, 30–32, 34, 35, 37, 45, 46
- HTML *HyperText Markup Language*. 6
- HTR *Handwritten Text Recognition*. 6
- HTTPS *Hypertext Transfer Protocol Secure*. 22
- HTTP *Hypertext Transfer Protocol*. 22
- IIF *International Image Interoperability Framework*. 15, 21–27
- IMAGINE Laboratoire d’Informatique Gaspard Monge. 6–8, 34, 35, 37
- INHA Institut national d’histoire de l’art. 18
- ISCD Institut des sciences du calcul et des données. 7
- JSON *JavaScript Object Notation*. 22, 23
- SVG *Scalable Vector Graphics*. 33
- SYRTE Systèmes de Référence Temps-Espace. 3, 6
- URI *Uniform Resource Identifier*. 22
- VHS *Vision artificielle et analyse Historique de la circulation de l’illustration Scientifique*. 6–8, 30, 32, 34, 36
- XML *eXtensible Markup Language*. 6
- BnF Bibliothèque nationale de France. 16, 18, 21
- EnHerit *Enhancing Heritage Image Databases*. 7
- Rmn-Grand Palais Réunion des musées nationaux-Grand Palais. 17

Table des matières

Résumé	iii
Remerciements	v
Introduction	xi
I Construire un corpus de numérisations pour le traitement par vision artificielle	1
1 Le projet EiDA	3
1.1 Contexte et objectifs du projet	3
1.1.1 Un projet de recherche en humanités numériques	3
1.1.2 Avant EiDA : le projet DISHAS	5
1.1.3 Acteurs du projet	6
1.2 Sources primaires	8
1.2.1 L’astronomie ptoléméenne : naissance et diffusion	8
1.2.2 Les diagrammes	10
2 Images et interopérabilité	15
2.1 L’image comme source	15
2.1.1 Construire un corpus d’images : enjeux et méthodes	15
2.1.2 Images et données ouvertes	19
2.2 Le standard IIIF	21
2.2.1 IIIF et les données ouvertes	21
2.2.2 IIIF, un modèle universel ?	24
3 Corpus historiques et jeux de données	29
3.1 Dimensions et cadre	29
3.1.1 La tentative de l’exhaustivité	29
3.1.2 Automatiser le traitement de corpus massifs	31
3.2 Objectifs scientifiques et possibilités numériques	34

3.2.1	Dialogue entre chercheurs et ingénieurs	34
3.2.2	Définir les pratiques	35
II De l'image à l'objet : intégrer l'apprentissage profond au traitement des sources historiques		39
4	L'apprentissage profond	41
4.1	Réseaux de neurones et <i>computer vision</i>	41
4.1.1	Des « neurones » pour le machine learning	41
4.1.2	« Voir », comprendre et traiter les images	41
4.2	Modèles de vision <i>off-the-shelf</i>	41
4.2.1	YOLOv5, docExtractor et autres modèles	41
4.2.2	Entraînement et <i>fine-tuning</i>	41
5	L'interface entre chercheurs et algorithme	43
5.1	Architecture de l'application	44
5.1.1	Une interface pour le dépôt des sources	44
5.1.2	Décrire les sources	44
5.1.3	Images et objets détectés : une nouvelle source ?	44
5.2	Créer un outil open source : penser une application réutilisable	44
5.2.1	De VHS à EiDA : adapter un modèle de données	44
5.2.2	Construire une application réutilisable	44
6	<i>Deep learning</i> et pratiques des chercheurs	45
6.1	Annoter sur un GPU : extractorAPI	45
6.1.1	Architecture du système	45
6.1.2	Cahier des charges et analyse des besoins	45
6.1.3	Programmation modulaire et <i>open source</i>	45
6.2	De la numérisation à l'annotation	45
6.2.1	<i>Workflow</i> d'annotation	45
6.2.2	Échanges et transformation des données	46
6.2.3	Interface d'annotation	46
6.3	Médiation et documentation	46
6.3.1	Séminaire DH et échanges avec les chercheurs	46
6.3.2	Documentation et Wiki : penser le réemploi du code	46

III Perspectives pour le traitement des sources : vers un outil pour l'édition et la recherche	47
7 Éditer des diagrammes	49
7.1 Édition critique des diagrammes astronomiques	50
7.1.1 Historique	50
7.1.2 Éditer les diagrammes en format numérique	50
7.2 De l'image aux vecteurs	50
7.2.1 Automatiser la transcription	50
7.2.2 Données d'entraînement et annotations pour la vectorisation	50
7.2.3 Diagrammes en SVG	50
8 Regroupement par similarité et <i>clustering</i>	51
8.1 <i>Similarity retrieval</i> et navigation des corpus	52
8.1.1 Principe et méthodes	52
8.1.2 Fouiller des corpus par l'image	52
8.2 Le <i>clustering</i> comme outil pour les chercheurs	52
8.2.1 Sous-section 1	52
8.2.2 Sous-section 2	52
8.2.3 Sous-section 3	52
9 Exploiter les résultats automatique	53
9.1 Titre section 1	54
9.1.1 Sous-section1	54
9.1.2 Sous-section 2	54
9.1.3 Sous-section 3	54
9.2 Titre section 2	54
9.2.1 Sous-section1	54
9.2.2 Sous-section 2	54
9.2.3 Sous-section 3	54
Conclusion	55
Annexes	59
Acronymes	59
Table des matières	61